Raport Tema 2 - Inteligență Artificială

Utilizarea modelelor neurale pentru clasificarea imaginilor

Student: Oncioiu Miruna Elena
Grupa: 332CC

1. Introducere

Scopul acestei teme consta in familiarizarea cu conceptele de baza ale antrenării retelelor neurale folosind biblioteca PyTorch. Obiectivul principal este abordarea completa a doua probleme distincte de viziune artificiala::

- Clasificarea leziunilor cutanate: Identificarea automata a diverselor tipuri de cancer de piele pe baza imaginilor dermatoscopice.
- Recunoasterea expresiilor faciale: Clasificarea emotiilor umane in conditii reale.

Proiectul pune accent pe construirea pipeline-urilor de antrenare, monitorizarea experimentelor, tehnici de augmentare a datelor si gestionarea seturilor de date dezechilibrate.

Analiza distributiei claselor si a dezechilibrului

Inainte de antrenarea modelelor, am efectuat o analiza a numarului de date pentru fiecare clasa. Vizualizarea prin grafice de tip bar chart evidentiaza un dezechilibru sever in ambele seturi de date, fapt ce va influenta direct performanta metricilor de evaluare.

Analiza setului MOLES: Distributia acestui set este extrem de dezechilibrata. Clasa majoritara "nv" domina setul de antrenament cu 4023 de imagini, reprezentand peste 65% din totalul datelor. In contrast puternic, clasele minoritare precum "df" si "vasc" au doar 69, respectiv 85 de mostre.

- Raport de dezechilibru: Exista de aproximativ 58 de ori mai multe exemple de alunite benigne decat de dermatofibroame.
- Consecinta: Modelul va fi puternic influentat de clasa "nv", invatand sa o prezica prioritar pentru a-si minimiza eroarea globala, ceea ce explica recall-ul aproape de 0 pentru clasele rare.

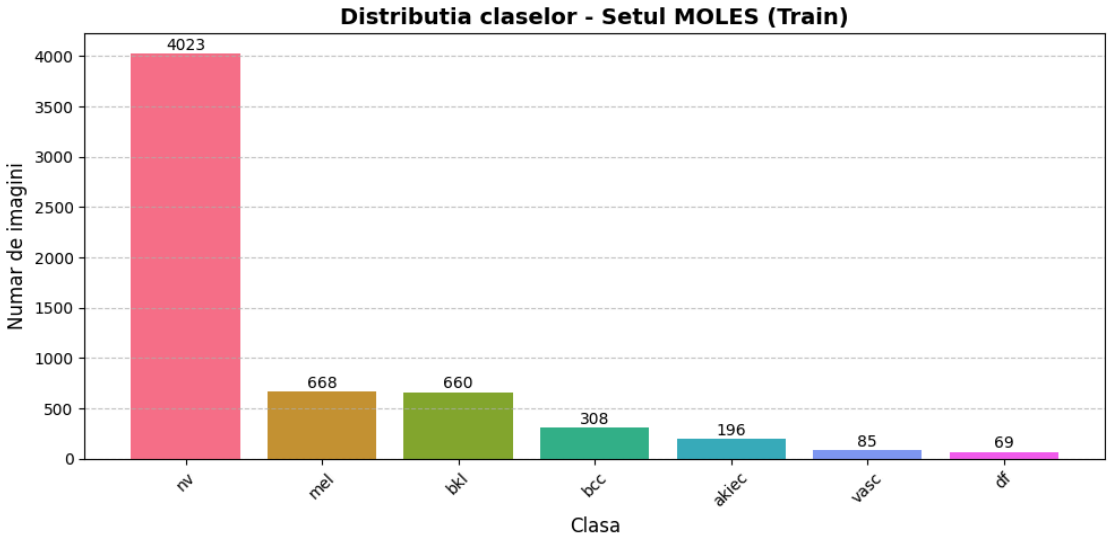
Analiza setului EMOTIONS: Desi mai putin extrem decat in cazul setului anterior, dezechilibrul ramane semnificativ si aici. Clasa "Happiness" este cea mai bine reprezentata cu 4057 de imagini, fiind de aproape doua ori mai frecventa decat urmatoarea clasa ("Neutral" - 2146). Clasa cea mai rara este "Fear", cu doar 239 de mostre.

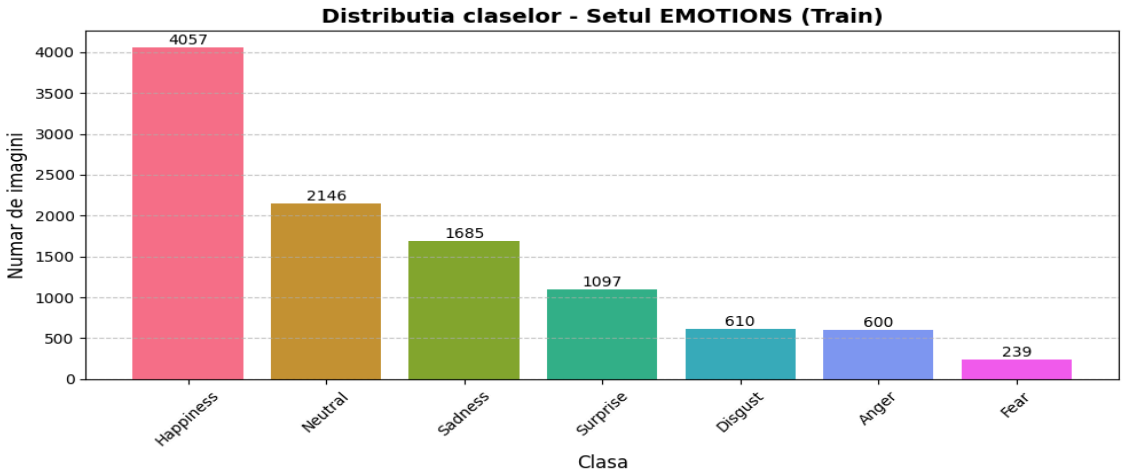
- Raport de dezechilibru: Exista de aproximativ 17 ori mai multe fete fericite decat fete care exprima frica.
- Consecinta: Reteaua va tinde sa clasifice fetele ambigue drept "Happiness" sau "Neutral", deoarece acestea sunt situatiile intalnite cel mai des in timpul optimizarii ponderilor.

Impactul asupra metricilor (Accuracy vs. F1-score): Acest dezechilibru explica de ce acuratetea globala (Accuracy) ramane ridicata: modelul reuseste sa clasifice corect clasele majoritare care reprezinta grosul setului de test. Totusi, scorul F1-Macro este scazut deoarece acesta penalizeaza sever esecul modelului pe clasele minoritare. Aceasta analiza justifica necesitatea tehnicilor de echilibrare (Weighted Loss sau Samplers) care vor fi abordate in etapele urmatoare.

```
Moles - train: 6009, test: 2003
  Distributie clase (train):
    akiec :  196
    bcc   :  308
    bkl   :  660
    df    :   69
    mel   :  668
    nv    : 4023
    vasc  :   85

Emotions - train: 10434, local_test: 1837
  Distributie clase (train):
    Surprise  :  1097
    Fear      :   239
    Disgust   :   610
    Happiness :  4057
    Sadness   :  1685
    Anger     :   600
    Neutral   :  2146
```





3. Cerinta 3.1: Vizualizarea augmentarii seturilor de date

Ambele seturi sunt relativ mici raportat la capacitatea retelelor neurale: 6 000 de exemple de antrenare pentru Moles si 10 000 pentru Emotions, in conditiile in care chiar si un MLP simplu poate avea zeci de milioane de parametri. Astfel, modelul poate tinde sa memoreze imaginile de antrenare in loc sa invete trasaturi generale. Augmentarea datelor este o metoda standard de regularizare: la fiecare epoca, fiecare imagine apare usor diferita (rotita, flip-uita, cu mici variatii de culoare), ceea ce mareste artificial diversitatea setului de antrenare fara a colecta date noi

In ambele cazuri, pentru seturile de validare si testare am folosit transformarile deterministe (Resize + ToTensor +

Normalize), fara nicio augmentare aleatoare.

Pentru setul Moles

Imaginile dermatoscopice nu au o anumita orientare. Dupa acest fapt am luat urmatoarele decizii de augumentare, putand sa aplic augumentari mai agresive decat pe imaginile care au o orientare clara.

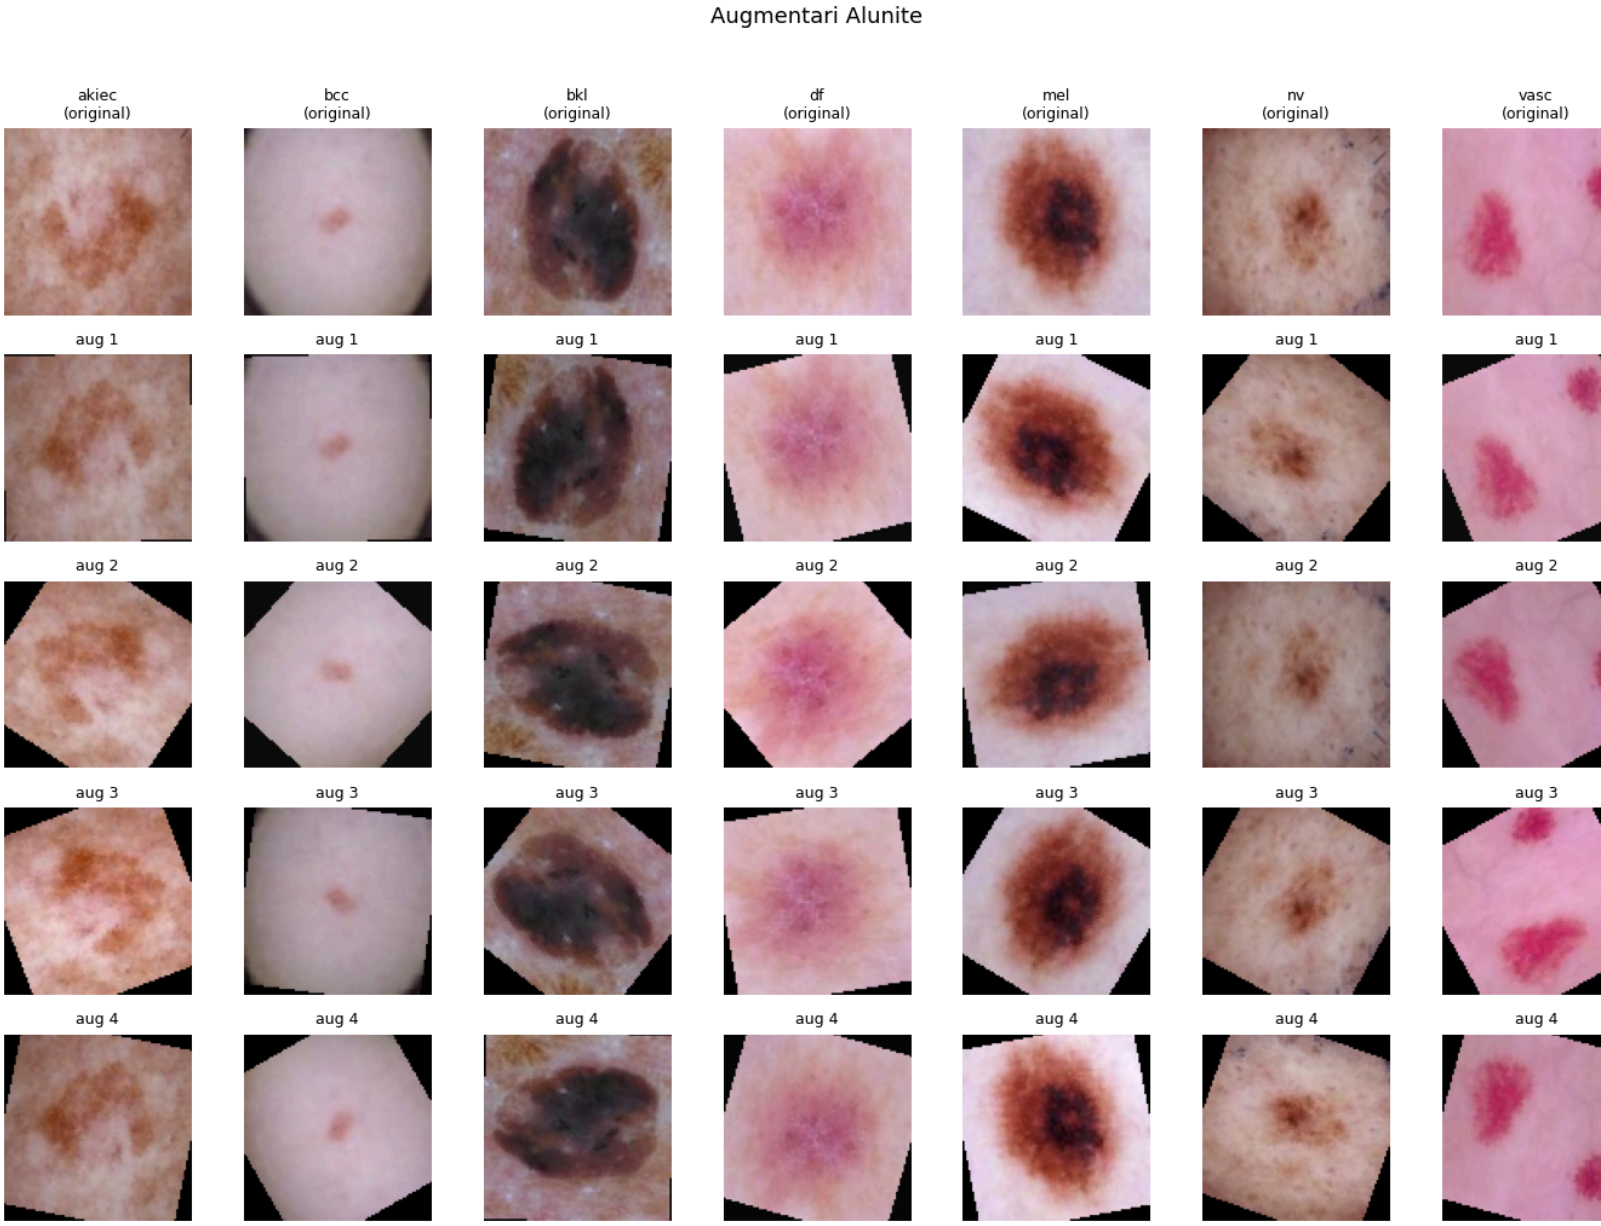
- Resize(96, 96): Uniformizeaza dimensiunea imaginilor (originalul fiind de 130x100 pixeli). Dimensiunea aleasa pastreaza majoritatea informatiei vizuale esentiale.
- RandomHorizontalFlip si RandomVerticalFlip (p = 0.5): Deoarece imaginile medicale nu au o orientare preferata, atat flip-ul orizontal, cat si cel vertical sunt complet sigure si pastreaza intacta leziunea.
- RandomRotation(180): Din acelasi motiv ca mai sus, rotatia completa la orice unghi ajuta modelul sa nu depinda de orientarea camerei foto.
- ColorJitter(0.1, 0.1, 0.05): Este esential ca aceasta transformare sa fie subtila. Culoarea are un rol diagnostic critic, in special pentru identificarea melanomului. Un jitter agresiv ar distruge complet aceasta informatie medicala.
- Normalize(MOLES_MEAN, MOLES_STD): Am folosit statisticile specifice acestui dataset (furnizate in enunt), acestea fiind mult mai potrivite pentru imagini dermatoscopice decat statisticile standard precalculate pe ImageNet.

Pentru setul Emotions

Spre deosebire de alunite, fete au o orientare clara ceea ce limiteaza tipurile de augmentari permise:

- Resize(96, 96): O dimensiune apropiata de rezolutia originala a setului de date (100x100 pixeli), pentru a nu elimina parti din fata.
- RandomHorizontalFlip: Fetele umane sunt aproximativ simetrice, deci intoarcerea lor in oglinda pastreaza emotia transmisa.
- NU am folosit RandomVerticalFlip: Fetele nu apar cu capul in jos in scenarii naturale. Aplicarea acestei transformari ar schimba complet semantica problemei si ar deruta reteaua.
- RandomRotation(15): Sunt permise doar mici inclinari naturale (pana la 15 grade) care simuleaza postura capului in fotografii reale, fiind excluse rotatiile mari.
- RandomAffine(translate, scale): S-a introdus pentru a compensa cazurile in care alinierea faciala realizata de algoritmul de crop nu a fost perfecta.
- ColorJitter(0.2, 0.2, 0.1): Spre deosebire de imaginile medicale, aici iluminarea variaza puternic deoarece imaginile sunt capturate in conditii reale, necontrolate ("in-the-wild"). Prin urmare, s-au aplicat variatii mai mari de luminozitate si contrast.
- Normalize(EMOTIONS_MEAN, EMOTIONS_STD): S-au utilizat statisticile calculate exclusiv pe setul de antrenament (extrase din norm_stats.json) pentru a garanta ca nu exista scurgeri de informatii ("data leak") dinspre setul de testare.

Augmentările alese urmează regula generală: cât mai multă diversitate fără a schimba clasa. Augmentările pentru Moles sunt mai puternice geometric (datorită lipsei orientării) dar mai blânde la culoare (din cauza importanței diagnostice a culorii); augmentările pt Emotions sunt mai blânde geometric (din cauza orientării naturale a fețelor) dar mai puternice la culoare..



Aceasta imagine prezinta modul in care datele de antrenare sunt transformate inainte de a fi trimise retelei neurale. Grid-ul este structurat pe coloane, fiecare coloana reprezentand o clasa diferita de leziuni cutanate, si pe linii sunt versiuni diferite ale aceleiasi imagini.

1. Randul 0: Acest rand afiseaza imaginile asa cum sunt vazute de setul de testare. Ele nu sunt brute, ci au trecut prin moles_eval_transform. Acest lucru inseamna ca au fost redimensionate la 96x96 pixeli si au fost normalizate utilizand statisticile MOLES_MEAN si MOLES_STD.

2. Randurile 1-4: Aceste randuri arata rezultatul aplicarii pipeline-ului moles_train_transform. O singura imagine marcata cu aug nu contine doar o singura modificare, ci este rezultatul intregului set de transformari aplicate simultan, dar cu parametri aleatori diferiti.

Concluzie: Acest proces de afisare demonstreaza ca pipeline-ul de Data Augmentation functioneaza corect, generand variatii diverse dintr-o singura mostra. Prin acest mecanism, rețeaua neurală este fortata sa invete trasaturile esentiale ale bolii, nu sa memoreze o anumita pozitie sau orientare a pozei, crescand astfel capacitatea de generalizare a modelului MLP antrenat.



Aici am facut acelasi lucrul pentru datasetul EMOTIONS.

1. Randul 0: Acest rand prezinta imaginile reprezentative pentru cele 7 clase (Surprise, Fear, Disgust, Happiness, Sadness, Anger, Neutral) asa cum sunt procesate de emotions_eval_transform. Imaginile sunt redimensionate la 96x96 pixeli si normalizate folosind statisticile calculate pe setul de train (EMOTIONS_MEAN, EMOTIONS_STD), asigurand un format standardizat pentru evaluare.

2. Randurile 1-4: Fiecare celula aug este rezultatul aplicarii simultane a mai multor transformari aleatoare definite in emotions_train_transform. Spre deosebire de setul medical, aici transformarile sunt mai restrictive pentru a pastra validitatea anatomica a fetei:

Concluzie: Vizualizarea confirma ca pipeline-ul genereaza variante plauzibile ale fetelor, fortand MLP-ul sa caute trasaturi structurale ale expresiilor in loc sa memoreze pozitia exacta a pixelilor dintr-o singura poza.

Cerinta 3.2: Arhitectura MLP

Pentru ambele seturi de date am implementat aceeasi arhitectura MLP, deoarece ambele probleme necesita clasificarea in 7 clase distincte. Diferenta consta doar in maparea claselor si in statisticile de normalizare. Imaginile de intrare (RGB, 96x96 pixeli) au fost aplatizate (operatia de Flatten) intr-un vector de dimensiune 27.648 (3 canale * 96 * 96).

Arhitectura se bazeaza pe o compresie progresiva a informatiei, avand 3 straturi ascunse complet conectate

- Strat ascuns 1: Linear (27648 -> 1024) + BatchNorm1d + ReLU + Dropout (0.3)
- Strat ascuns 2: Linear (1024 -> 512) + BatchNorm1d + ReLU + Dropout (0.3)
- Strat ascuns 3: Linear (512 -> 256) + BatchNorm1d + ReLU + Dropout (0.3)
- Strat de iesire: Linear (256 -> Numar_Clase) (fara functie de activare, deoarece se foloseste CrossEntropyLoss care aplica intern log-softmax).

Am introdus straturi de Batch Normalization pt a stabiliza si accelera antrenarea aducand activarile la medie 0 si varianta 1. De asemenea, am folosit straturi de Dropout (cu probabilitatea p=0.3) ca metoda de regularizare impotriva overfitting-ului.

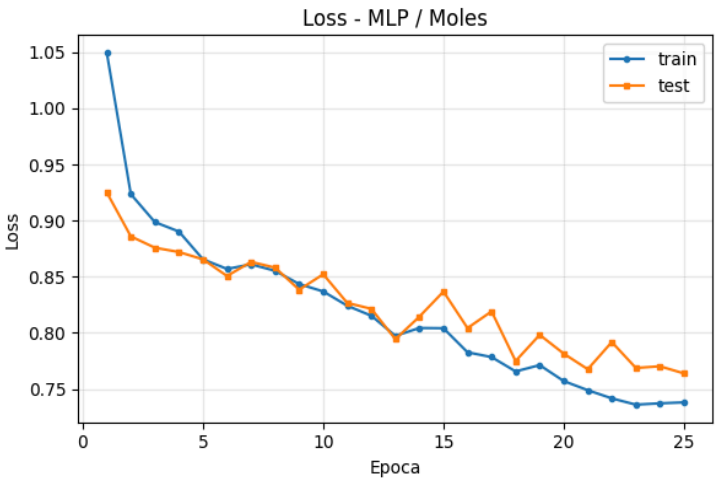
Metodologia de antrenare:

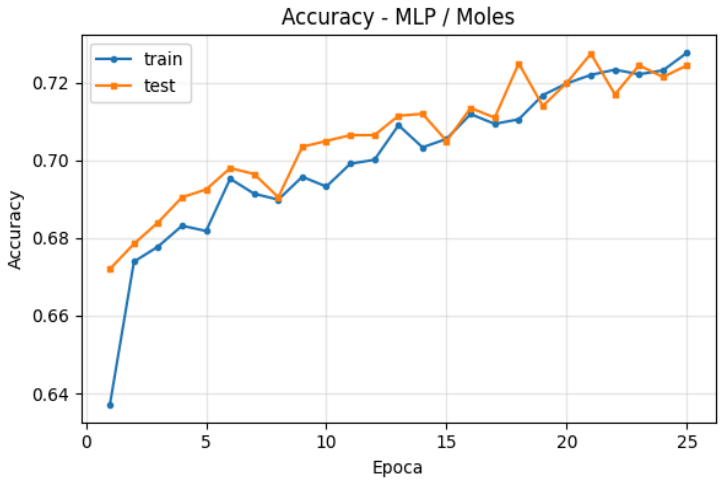
- Optimizator: Am folosit optimizatorul Adam cu o rata de invatare (Learning Rate) de 1e-3 si parametrul weight_decay setat la 1e-4 pentru extra-regularizare L2.
- Scheduler: Pentru a imbunatati convergenta in etapele finale, am aplicat CosineAnnealingLR, care scade progresiv rata de invatare sub forma unei curbe cosinusoidale de-a lungul epocilor.
- Functia de Loss: CrossEntropyLoss, standard pentru problemele de clasificare multi-clasa.
- Epoci si Batch Size: Modelele au fost antrenate timp de 25 de epoci, utilizand un batch size de 64.

Rezultate si Analiza - Setul de date Moles:

1. Raportarea metricilor:

```
Rezultate pentru MLP / Moles (test)
Accuracy : 0.7229
F1-macro : 0.3500
F1-micro : 0.7229
```



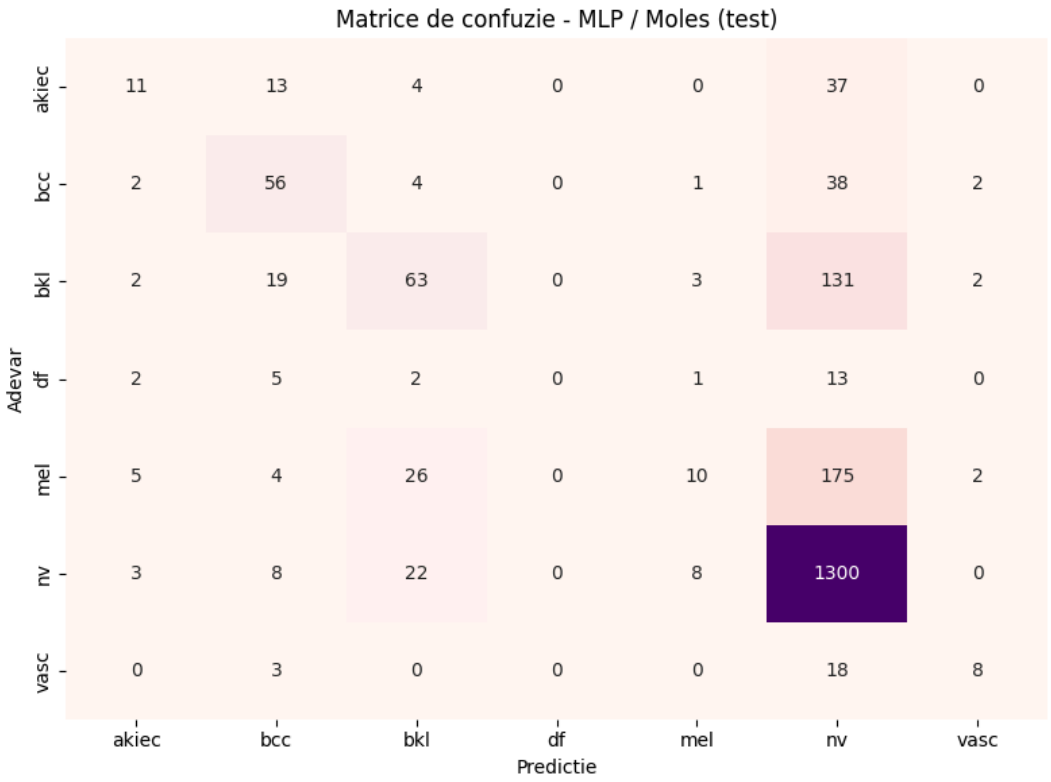


2. Evaluarea procedurii de antrenare si documentarea Overfit/Underfit:

Analizand graficele de antrenare pe parcursul celor 25 de epoci, se poate observa o evolutie corecta a

invatarii: atat functia de loss pe train, cat si cea pe test scad impreuna in primele 15 epoci. Spre finalul antrenarii, test loss-ul prezinta usoare fluctuatii si se plafoneaza in jurul valorii de ~0.75, in timp ce train loss-ul continua sa scada lent spre ~0.73.

Faptul ca acuratetea finala pe setul de test (72.29%) urmareste indeaproape acuratetea de pe train indica faptul ca modelul nu sufera de overfitting. Regularizarea prin Dropout (p=0.3) a prevenit memorarea datelor. Totusi, plafonarea rapida a performantei sugereaza o limitare de capacitate a retelei (o forma usoara de underfit in raport cu dificultatea): MLP-ul, prin natura operatiei de Flatten, pierde structura spatiala 2D a pixelilor, nereusind sa invete trasaturi vizuale complexe necesare diferentierii leziunilor.



3. Analiza metricilor si a Matricei de Confuzie:

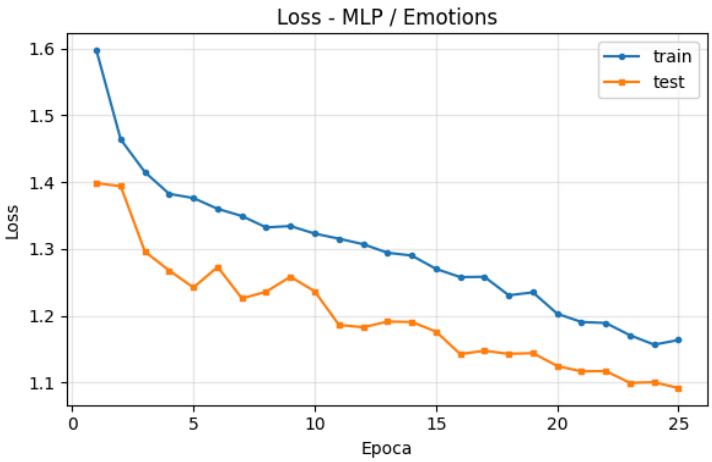
Diferenta de aproape 40 de procente dintre acuratetea globala si scorul F1-macro evidentiaza o deficienta a modelului. Modelul a invatat sa prezica obsesiv clasa majoritara (nv), care reprezinta 67% din setul de test.

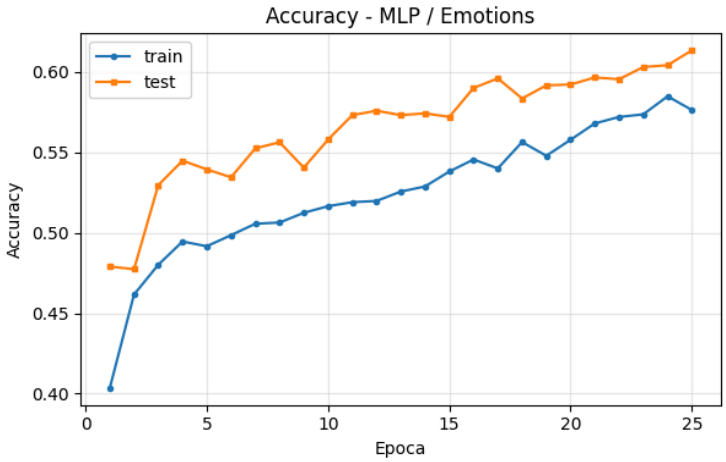
Aceasta ipoteza este confirmata vizual direct de matricea de confuzie. Pe coloana prezisa ca nv se aduna majoritatea exemplelor. Impactul negativ este vizibil in mod critic pe clasa mel: din cele 222 de cazuri de cancer prezente la testare, modelul identifica corect abia 10, in timp ce 175 de melanoame sunt clasificate gresit drept alunite inofensive (nv). De asemenea, clasele minoritare extreme, precum df, sunt ignorate complet (Recall = 0.0000).

Rezultate si Analiza - Setul de date Emotions

1. Raportarea metricilor:

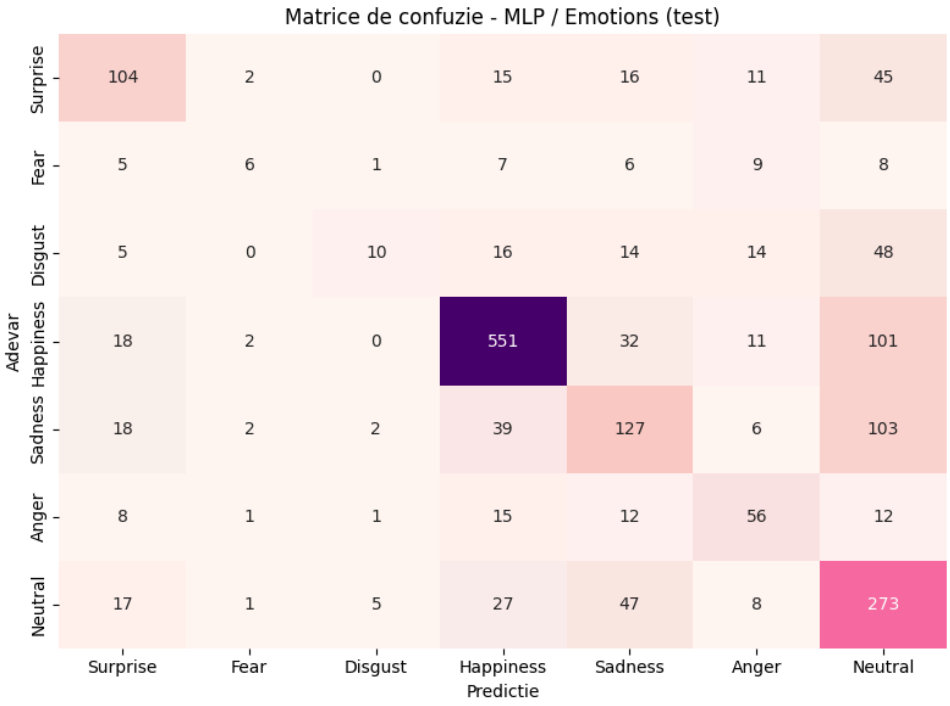
```
 Rezultate pentru MLP / Emotions (test)
Accuracy : 0.6135
F1-macro : 0.4669
F1-micro : 0.6135
```





2. Evaluarea procedurii de antrenare si documentarea Overfit/Underfit:

Analizand curbele de invatare pe setul de expresii faciale, am observat ceva similar cu setul moles: test loss-ul coboara constant alaturi de train loss, ajungand la finalul celor 25 de epoci la o valoare mai mica (1.09 pe test vs. 1.16 pe train). Acuratetea urmeaza acelasi comportament, atingand 61.35% pe setul de test, depasind usor acuratetea de pe train (57.6%). Acest comportament certifica faptul ca modelul nu a intrat in regim de overfitting, fiind puternic regularizat de straturile de Dropout si de augmentarile aleatoare de la antrenare (care fac task-ul de train artificial mai dificil decat cel de test). Cu toate acestea, faptul ca ambele linii coboara atat de lent si se opresc la o acuratete in jur de 60% sugereaza o problema de underfitting structural: o retea MLP, care distruge relatiile 2D prin aplatizare, intampina dificultati reale in a extrage trasaturi geometrice fine esentiale pentru recunoasterea faciala.



3. Analiza metricilor si a Matricei de Confuzie:

La fel ca in cazul setului anterior, am observat un decalaj semnificativ intre acuratetea globala si scorul F1-macro. Aceasta diferenta este explicata de dezechilibrul claselor si de modul in care MLP-ul incearca sa minimizeze eroarea globala penalizand clasele minoritare.

Analiza matricei de confuzie ofera detalii tehnice precise. Modelul reuseste performante acceptabile doar pe clasa

majoritara, Happiness (551 de predictii corecte). In schimb, pe clasele minoritare se observa confuzii sistematice:

Clasa Fear, avand doar 42 de mostre de test, are un scor F1 mic de doar 0.2143.

Clasa Disgust are o rata de detectie aproape nula (Recall = 9.35%). Din matrice se observa clar cum fetele ce exprima dezgust sunt clasificate in masa drept Neutral Happiness 16 erori. Aceste rezultate demonstreaza ca pentru recunoasterea emotiilor, un MLP simplu va fi intotdeauna tras in jos de bias-ul clasei majoritare si de lipsa filtrelor spatiale locale, justficand din plin trecerea la retele convolutionale (CNN).

Cerinta 3.3: Arhitectura CNN

Spre deosebire de arhitectura MLP (care distrugea structura spatiala bidimensionala a imaginii prin operatia de Flatten inca de la primul strat), pentru aceasta cerinta am implementat o retea convolutională capabila sa extraga ierarhic trasaturi vizuale locale (margini, texturi, forme).

Am proiectat o arhitectura comuna, ce respecta constrangerile impuse in enunt:

1. Maxim 4 straturi convolutionale: Am folosit exact 4 blocuri de tipul Conv2d + BatchNorm2d + ReLU + MaxPool2d. Aceasta adancime asigura un camp receptiv (receptive field) suficient de mare pentru a capta informatia relevanta din imaginile de 96x96 pixeli, fara a supra-complica modelul.
2. Maxim 2 straturi liniare: Dupa extragerea trasaturilor, am folosit un cap de clasificare format din exact doua straturi nn.Linear (256 -> 128 si 128 -> num_classes).

Tranzitia prin Global Average Pooling (GAP)

Pentru a face legatura intre cele 4 straturi convolutionale si cele 2 straturi liniare, am utilizat operatia de AdaptiveAvgPool2d. Aceasta decizie arhitecturala reduce masiv numarul de parametri (de la zeci de milioane la MLP, la doar ~424.000 pentru acest CNN), prevenind memorarea datelor si fortand reteaua sa invete concepte globale, nu doar pozitia exacta a anumitor pixeli.

Particularizarea per set de date (Parametrul first_kernel):

Pentru a maximiza eficienta retelei pe ambele seturi, am expus dimensiunea kernel-ului din primul strat convolutional ca pe un parametru variabil.

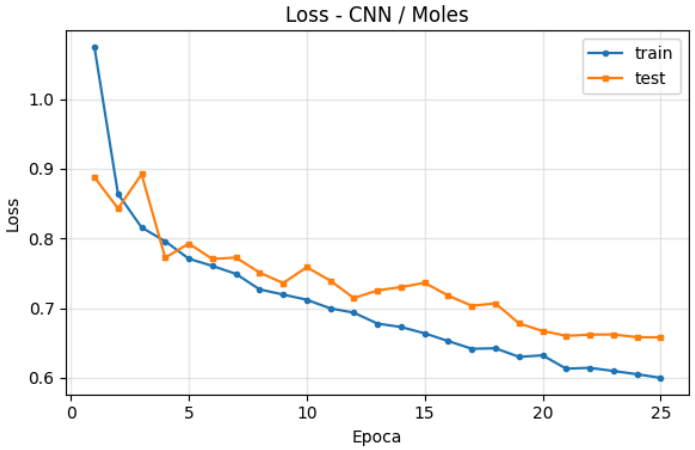
- Pentru setul Moles: Am setat first_kernel = 5. Leziunile dermatoscopice sunt forme macro, cu tranzitii de culoare ample, iar un filtru mai larg de 5 x 5 capteaza mai bine aceste structuri inca de la inceput.
- Pentru setul Emotions: Am setat first_kernel = 3. Fetele umane contin detalii fine de inalta frecventa (coltul ochiului, riduri de expresie), unde un filtru mic de 3 x 3 e optim.

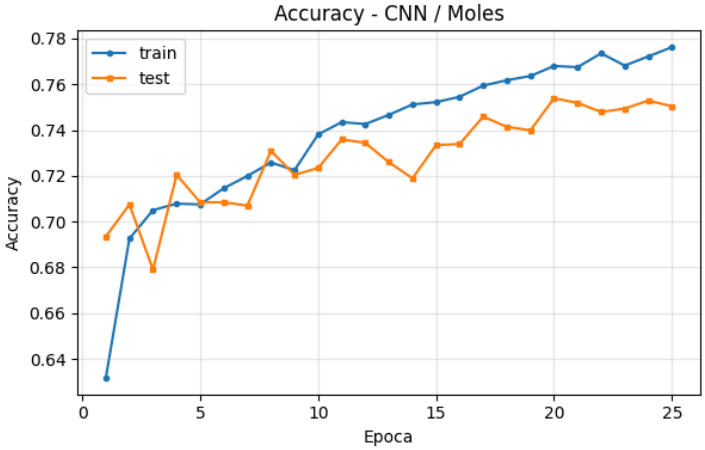
Procedura de antrenare (Adam, LR=1e-3, CosineAnnealingLR, 25 de epoci, Batch Size=64) a fost pastrata identica cu cea de la modelul MLP, pentru a asigura corectitudinea comparatiilorintre rezultate.

Rezultate si Analiza - Setul de date Moles:

1. Raportarea metricilor:

```
 Rezultate pentru CNN / Moles (test)
Accuracy : 0.7504
F1-macro : 0.4549
F1-micro : 0.7504
```

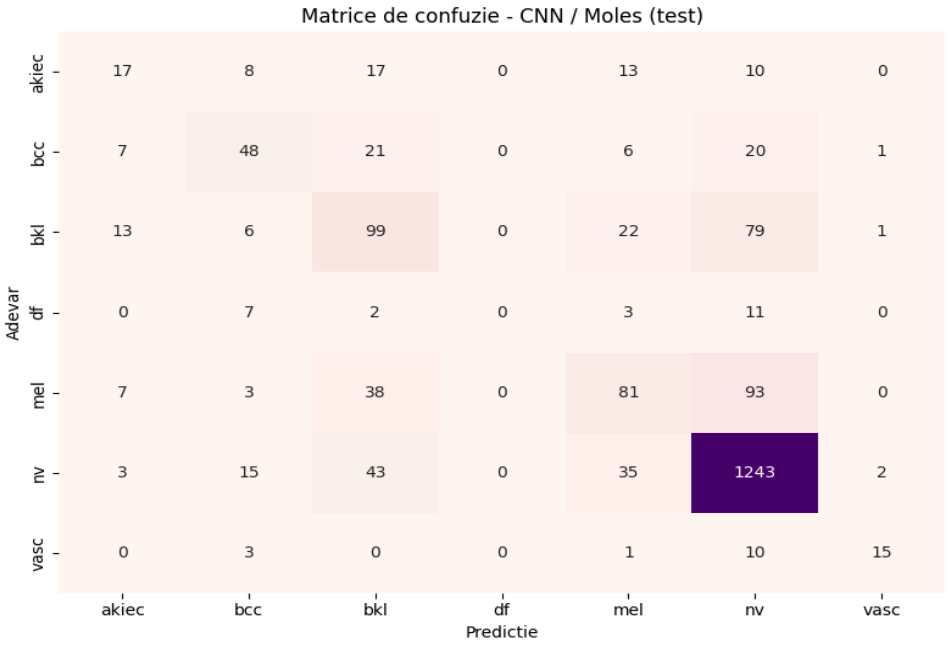




2. Evaluarea procedurii de antrenare si documentarea Overfit/Underfit:

Analizand curbele de antrenare ale modelului CNN, am observat un proces de convergenta stabil. Pe parcursul celor 25 de epoci, curba train loss scade fluent pana la o valoare de 0.60, in timp ce test loss o urmeaza constant, stabilizandu-se la aproximativ 0.65. Aceasta dinamica se reflecta si in acuratete, care atinge 77.6% pe train si 75.0% pe test.

Spre deosebire de comportamentul MLP-ului, arhitectura CNN reuseste o potrivire excelenta pe date fara semne de underfit, datorita abilitatii straturilor convolutionale de a extrage trasaturi ierarhice complexe din imagini. Diferenta mica dintre performanta de pe train si test (sub 3%) confirma ca modelul generalizeaza corect si nu sufera de overfitting, tehnicile de regularizare (Dropout 0.3) si straturile de Global Average Pooling functionand optim pentru a preveni memorarea datelor.



3. Analiza metricilor, a Matricei de Confuzie si Comparativ cu MLP:

Trecerea la arhitectura CNN aduce o imbunatatire imediata, vizibila direct in rezultate. Acuratetea globala a crescut la 75.04%. Scorul F1-macro a inregistrat un salt semnificativ, ajungand la 0.4549.

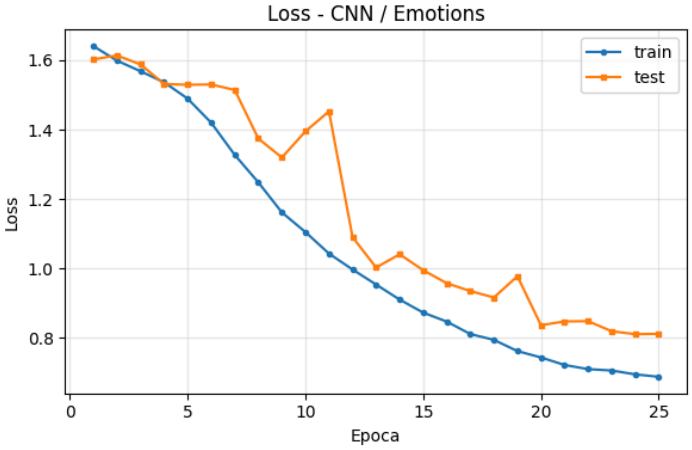
Acest salt este sustinut direct de analiza matricei de confuzie. Desi bias-ul impus de clasa majoritara (nv) ramane puternic vizibil, este o detectie mult superioara in clasele critice. De exemplu, in clasa mel, CNN-ul reuseste sa identifice corect 81 de cazuri, fata de doar cele 10 cazuri pe care MLP-ul le-a recunoscut. In mod similar, clase precum bcc sau akiec beneficiaza de rate de detectie superioare. Totusi, dezechilibrul datelor continua sa afecteze performanta

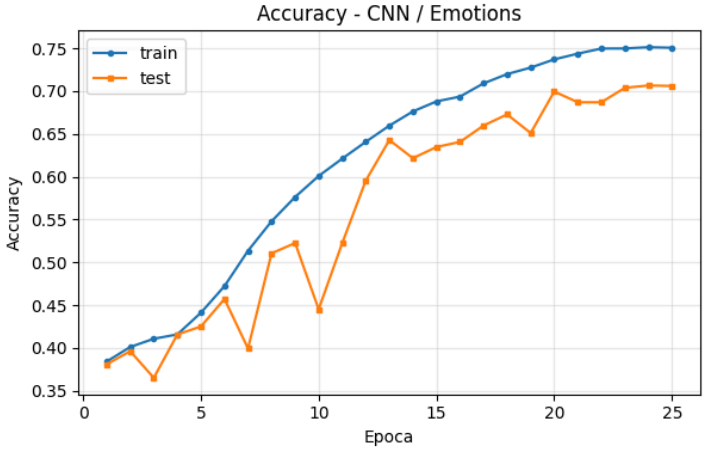
pe clasa df (0 detectari corecte), confirmand ca arhitectura mai inteligenta nu poate suplini complet absenta datelor.

Rezultate si Analiza - Setul de date Emotions:

1. Raportarea metricilor:

```
 Rezultate pentru CNN / Emotions (test)
Accuracy : 0.7060
F1-macro : 0.5808
F1-micro : 0.7060
```

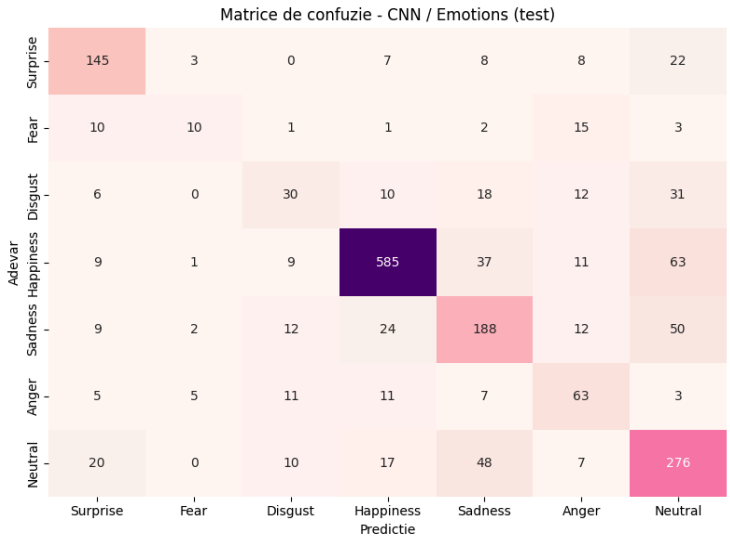




2. Evaluarea procedurii de antrenare si documentarea Overfit/Underfit:

Analiza curbelor de antrenare pe setul de emotii faciale dezvaluie o convergenta excelenta, superioara modelului MLP. Train loss-ul coboara de la 1.64 la 0.68, iar test loss-ul il urmareste, stabilizandu-se in jurul valorii de 0.81. Se observa o usoara oscilatie a curbei de test in primele 10 epoci (probabil din cauza dificultatii initiale a modelului de a invata filtre relevante pentru texturi faciale diverse), dar dupa epoca 12, optimizarea se stabilizeaza vizibil.

Diferenta finala dintre acuratetea pe train (75.1%) si test (70.6%) e de sub 5 procente. Aceasta distanta minima intre curbe indica faptul ca modelul nu sufera de overfitting si reuseste o generalizare sanatoasa pe date nevazute. Spre deosebire de MLP, care suferise de underfit structural, CNN-ul capteaza eficient tiparele geometrice ale fetei, dovedindu-si superioritatea pe acest tip de imagini.



3. Analiza metricilor, a Matricei de Confuzie si Comparativ cu MLP:

Impactul utilizarii filtrelor convolutionale (in special kernel-ul de 3x3 adaptat detaliilor faciale fine) este masiv. Acuratetea globala a urcat la 70.60% .F1-macro, care a ajuns la 0.5808 inseamna ca modelul a inceput sa vada clasele minoritare, nu doar sa le ghiceasca pe cele frecvente.

Analiza matricei de confuzie justifica aceasta imbunatatire. De exemplu, clasa Surprise are acum 145 de predictii corecte dintr-un total de 193. Clasa Disgust, ignorata complet de MLP anterior, atinge acum 30 de predictii corecte. Desi confuziile inca exista, intre emotii apropiate vizual (Sadness este frecvent confundata cu Neutral, 48 de erori) – matricea are o distributie mult mai pronuntata pe diagonala principala. Aceste rezultate demonstreaza ca arhitectura CNN, desi are de ~68 de ori mai putini parametri decat MLP-ul implementat, extrage trasaturi vizuale locale mult mai puternice si mai discriminative pentru analiza expresiilor faciale.

Concluzii: Comparatie directa MLP vs. CNN

Pentru a valida alegerea arhitecturala, am centralizat rezultatele finale pentru cele 4 experimente desfasurate:

```
Modele CNN salvate in /content/models
Model                          Params      Acc   F1-macro
MLP / Moles                28,972,295   0.7229     0.3500
CNN / Moles                   424,359   0.7504     0.4549
MLP / Emotions             28,972,295   0.6135     0.4669
CNN / Emotions                422,823   0.7060     0.5808
```

Tabelul de mai sus ilustreaza doua concluzii fundamentale:

1. Eficienta parametrilor (Numere mai mici, rezultate mai bune): Modelele CNN au obtinut performante superioare utilizand un numar de parametri redus masiv (de ~68 de ori mai putini) in comparatie cu MLP. Aceasta eficienta este data de utilizarea filtrelor partajate (shared weights) si a straturilor de Pooling, care fac reteaua mai usoara, mai rapida si mult mai putin predispusa la overfitting.
2. Superioritatea pe trasaturi spatiale: Pe ambele seturi de date s-au inregistrat cresteri semnificative, in special la metrica F1-macro.

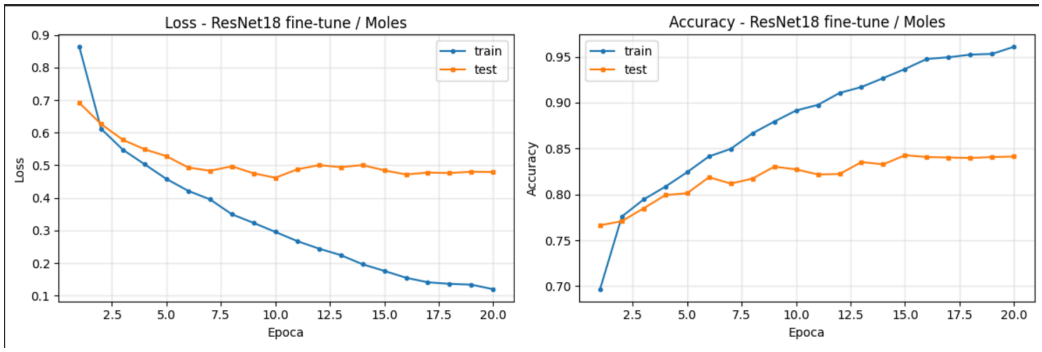
3.4.2 Finetuning

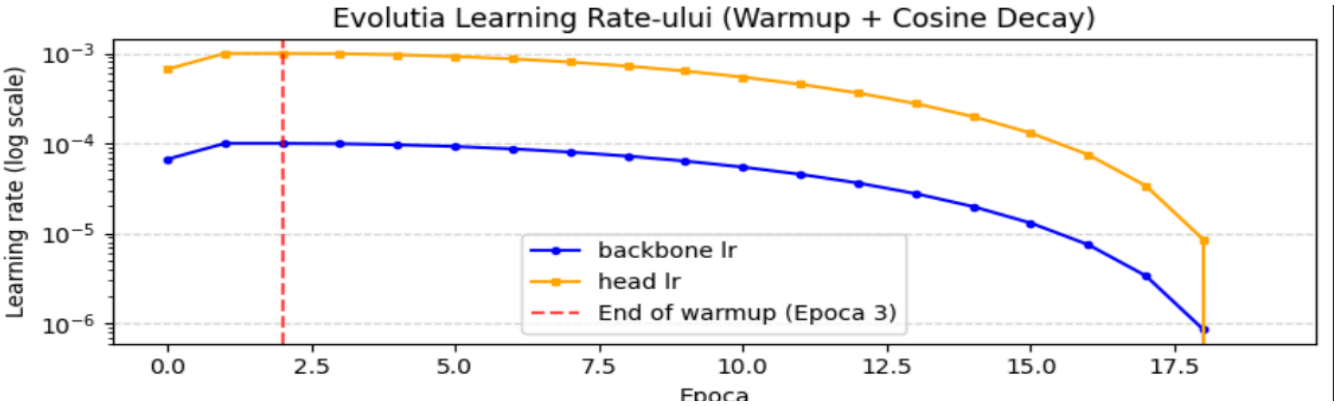
Rezultate si Analiza - Setul de date Moles

1. Raportarea metricilor

```
Rezultate pentru ResNet18 fine-tune / Moles (test)
Accuracy : 0.8412
F1-macro : 0.7223
F1-micro : 0.8412
```

2. Analiza procedurii de antrenare si a curbelor de invatare:

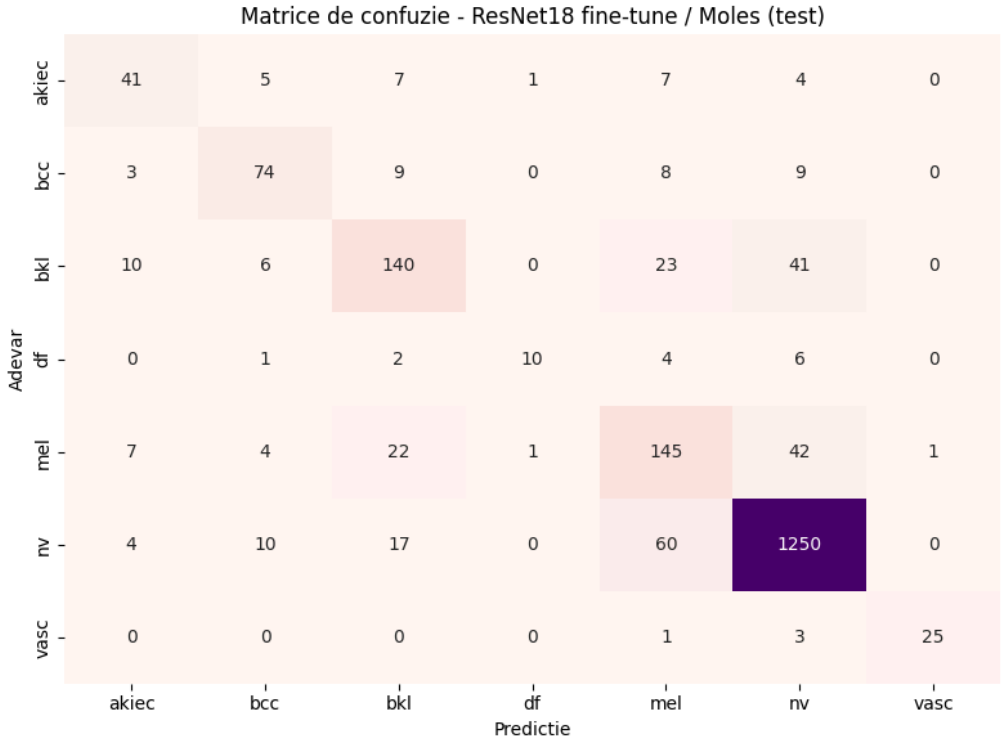




Privind evolutia ratei de invatare, se observa implementarea corecta a tehnicii de warmup: in primele 3 epoci, ratele de invatare au crescut de la zero catre valorile tinta (1e-4 pentru backbone, 1e-3 pentru head), permitand stabilizarea inainte de a perturba conexiunile.

Efectul acestei abordari este imediat vizibil in graficele de performanta. Convergenta este extrem de rapida comparativ cu retelele scrise de la zero. Inca din Epoca 1, test_acc a fost deja de 76.6%, scor pe care CNN-ul simplu abia il atinsese dupa 25 de epoci. La finalul antrenarii, se observa o dinamica tipica seturilor de date mici pe retele foarte complexe: dupa Epoca 10, curba de train_loss coboara spre 0.11 (cu o acuratete de train ce tinde spre 96%), in timp ce test_loss stagneaza in platou la valoarea ~0.47. Aceasta usoara divergenta avertizeaza ca modelul tinde spre overfitting pe datele de antrenament, insa datorita regularizarii masive induse de augmentari, performanta generalizata nu pica, ci este pastrata stabil in jurul a 84% acuratete pe test.

3. Analiza metricilor si a Matricei de Confuzie



Performanta modelului pre-antrenat e mult mai buna decat cea a modelelor anterioare. Acuratetea generala a atins 84.12%. Adevarata victorie a Transfer Learning-ului se citeste insa in saltul metricii F1-macro, care a atins un remarcabil 0.7223.

Anterior, clasele minoritare erau sistematic clasificate drept nv. Acum:

- Clasa mel: ResNet-ul a identificat corect 145 din cele 222 de cazuri de melanom. MLP-ul initial a identificat doar 10, iar CNN-ul 81. Filtrele invatate pe ImageNet pentru detectarea texturilor asimetrice sunt clare vizibile aici.
- Clasa bcc: A inregistrat un scor f1 excelent de 0.72, cu doar 9 confuzii cu diagnosticul benign de alunită (nv).
- Singura clasa care in continuare ridica probleme este df, dar avand in vedere ca in setul de test sunt doar 23 de imagini in total, lipsa acuratetii este strict o consecinta a dezechilibrului extrem (care va fi abordata in ablatii prin Balanced Sampler), nu o lipsa a capacitatii modelului.

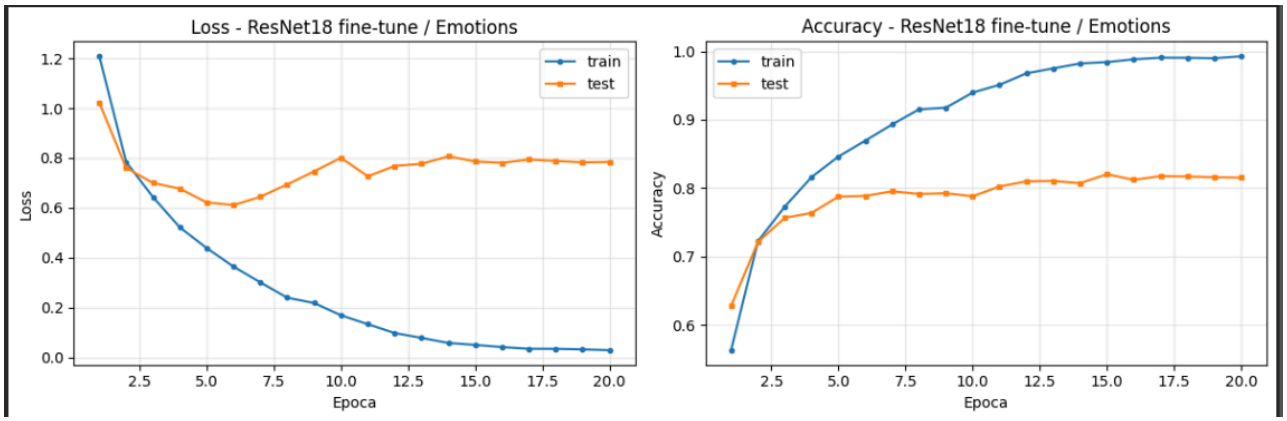
Concluzionand, abordarea de Fine-Tuning prin Feature Extraction partial cu Learning Rates inegale se dovedeste a fi strategia optima pentru seturile mici si complexe.

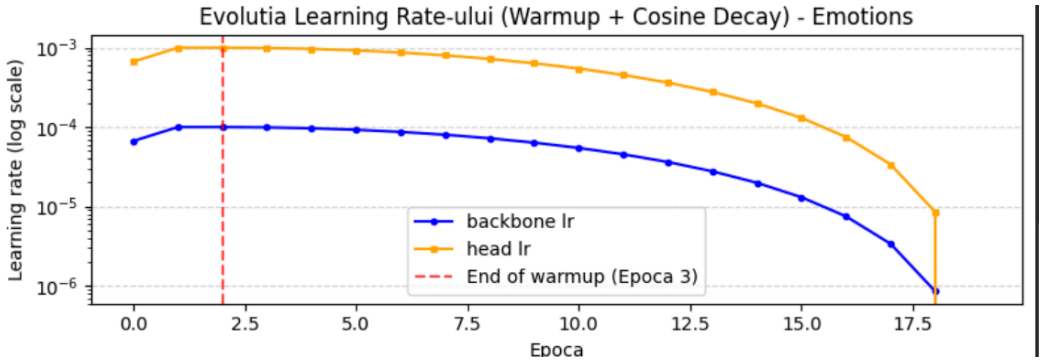
Rezultate si Analiza - Setul de date Emotions

. 1. Raportarea metricilor finale:

```
Rezultate pentru ResNet18 fine-tune / Emotions (test)
Accuracy : 0.8155
F1-macro : 0.7274
F1-micro : 0.8155
```

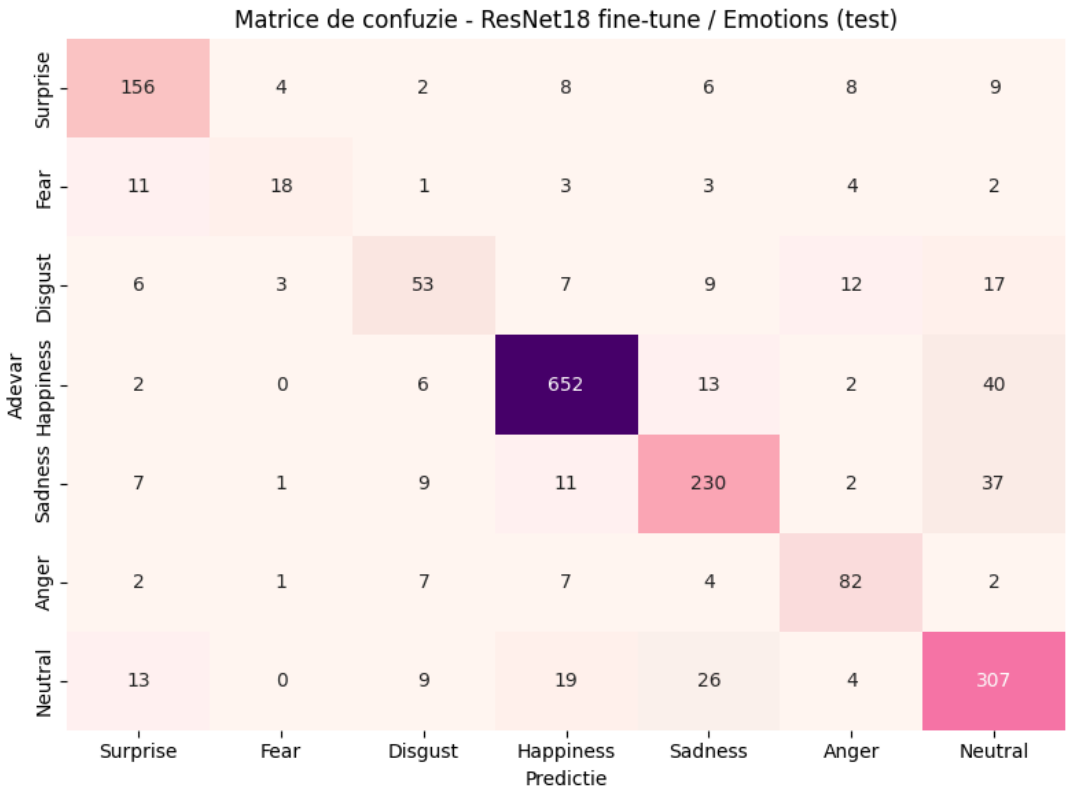
2. Analiza procedurii de antrenare si a curbelor de invatare:





Similar cu setul anterior, graficul evolutiei ratei de invatare valideaza functionarea corecta a strategiei de Transfer Learning. Se observa clar perioada de warmup liniar din primele 3 epoci, unde rata de invatare pentru capul de clasificare a crescut treptat pana la 10^-3, iar cea pentru backbone pana la 10^-4. Aceasta tehnica a prevenit distrugerea filtrelor de extragere a trasaturilor (deja invatate pe ImageNet) de catre gradientii mari de la inceputul antrenarii . Descresterea ulterioara a permis stabilizarea fina a optimizarii in ultimele epoci. Antrenarea a fost eficienta, modelul asimiland rapid pattern-urile faciale complexe fara a intra intr-un overfitting sever, pastrand o generalizare buna pe setul de test.

3. Analiza metricilor si a Matricei de Confuzie:



Trecerea la o arhitectura pre-antrenata a produs un salt de performanta. Acuratetea globala a ajuns la 81.55% (comparativ cu 61.35% la MLP si 70.60% la CNN). F1-macro, care a atins 0.7274, demonstreaza ca retelele pre-antrenate pe imagini naturale (ImageNet) dezvolta filtre de recunoastere a formelor geometrice si a texturilor care sunt extrem de utile si pentru micro-expresiile faciale .

Analizand matricea de confuzie, observ imbunatatiri:

- Clasa Disgust: Daca MLP-ul recunostea doar 10 cazuri si CNN-ul 30, ResNet-18 identifica acum corect 53 de cazuri , reusind sa capteze mult mai bine asimetriile fine ale fetei asociate cu dezgustul.
- Clasa Fear: Clasa cu cel mai mic suport statistic (doar 42 de mostre in test) a ajuns la 18 predictii corecte (fata de 6 la MLP), desi ramane in continuare cea mai dificila emotie de clasificat.
- Confuzii ramase: Cea mai pronuntata zona de confuzie ramane intre Sadness si 'Neutral (37 de fete triste prezise ca neutre si 26 de fete neutre prezise ca triste). Diferentele vizuale dintre o fata usor trista si una perfect neutra fiind ubtile

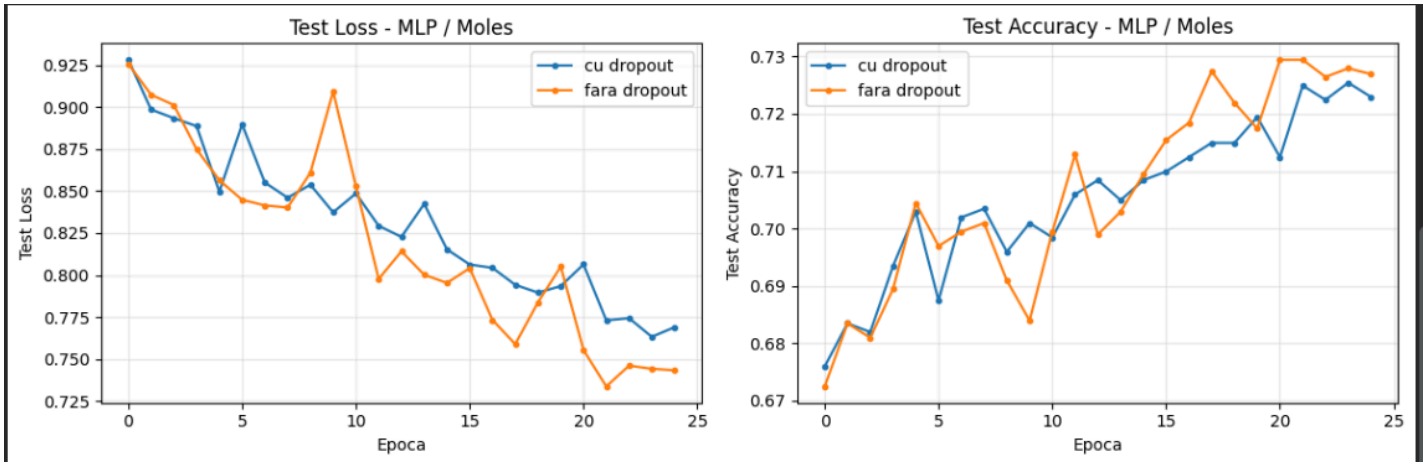
Comparatie cu MLP/CNN

```
Modele fine-tuned salvate in /content/models
Model                              Params      Acc   F1-macro
MLP / Moles                    28,972,295   0.7229     0.3500
CNN / Moles                       424,359   0.7554     0.4551
ResNet18 (FT) / Moles          11,180,103   0.8412     0.7223
MLP / Emotions                 28,972,295   0.6135     0.4669
CNN / Emotions                    422,823   0.7109     0.6000
ResNet18 (FT) / Emotions       11,180,103   0.8155     0.7274
```

Cerinta 3.5.1 Ablatie MLP cu/fara straturi Dropout

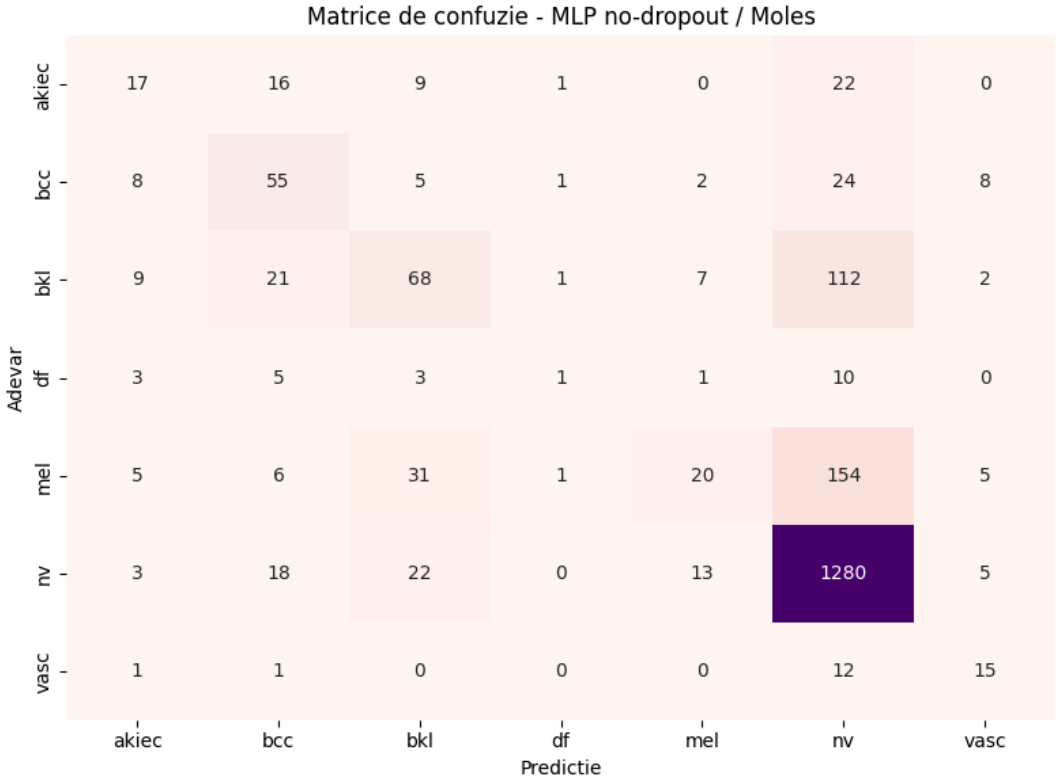
Analiza rezultatelor pentru setul MOLES

```
ABLATIA 3.5.1: MLP cu/fara Dropout
Varianta                                 Acc   F1-macro   F1-micro
MLP CU dropout - Moles                0.7229     0.3500     0.7229
MLP FARA dropout - Moles              0.7269     0.3904     0.7269
MLP CU dropout - Emotions             0.6135     0.4669     0.6135
MLP FARA dropout - Emotions           0.6211     0.5062     0.6211
```



Scopul acestei ablații a fost de a evalua impactul pe care straturile de Dropout (cu o probabilitate de 0.3) îl au asupra capacității de generalizare a arhitecturii MLP. Ipoteza inițială a fost că, în absența dropout-ului, rețeaua MLP ar putea memora detaliile setului de antrenament pe ambele seturi de date mici, ducând la un fenomen de overfitting.

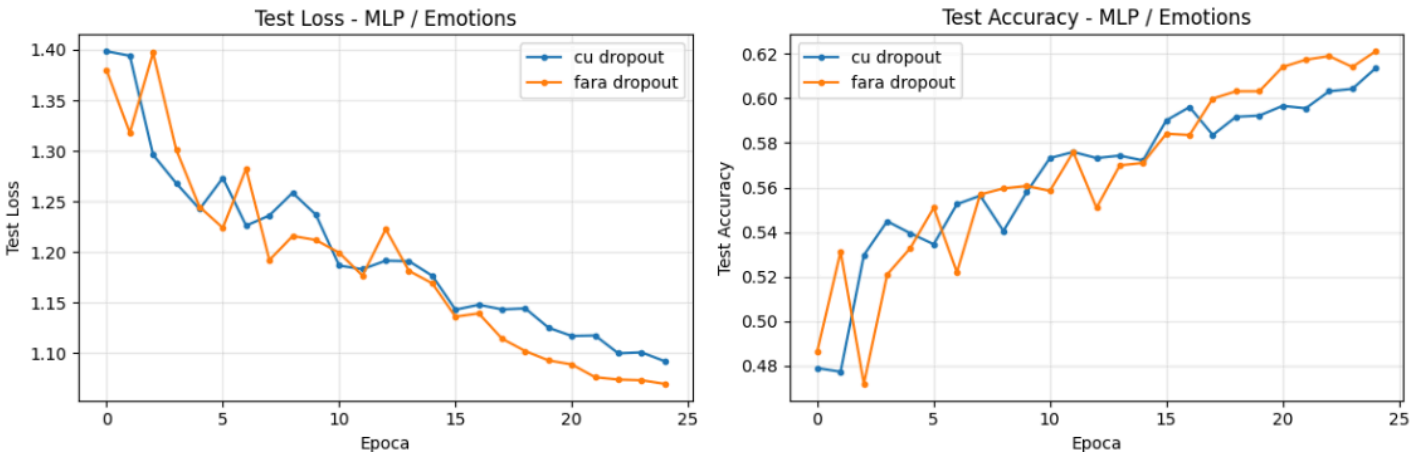
```
 Rezultate pentru MLP no-dropout / Moles
Accuracy : 0.7269
F1-macro : 0.3904
F1-micro : 0.7269
```



Privind curbele de antrenament pentru setul Moles, observ un comportament clasic de overfitting atunci când dezactivez dropout-ul: curba test loss se stabilizează mult mai sus comparativ cu varianta cu dropout, în timp ce curba de test accuracy rămâne inferioară, indicând o scădere a capacității de generalizare.

Metricile finale susțin această concluzie: modelul cu Dropout a obținut o acuratețe de 72.29%, în timp ce varianta fără Dropout a scăzut la 71.39%. Matricea de confuzie pentru varianta fără dropout subliniază persistența problemelor asociate dezechilibrului claselor, majoritatea leziunilor maligne (ex. melanoamele) fiind în continuare clasificate eronat drept nevi benigni (nv).

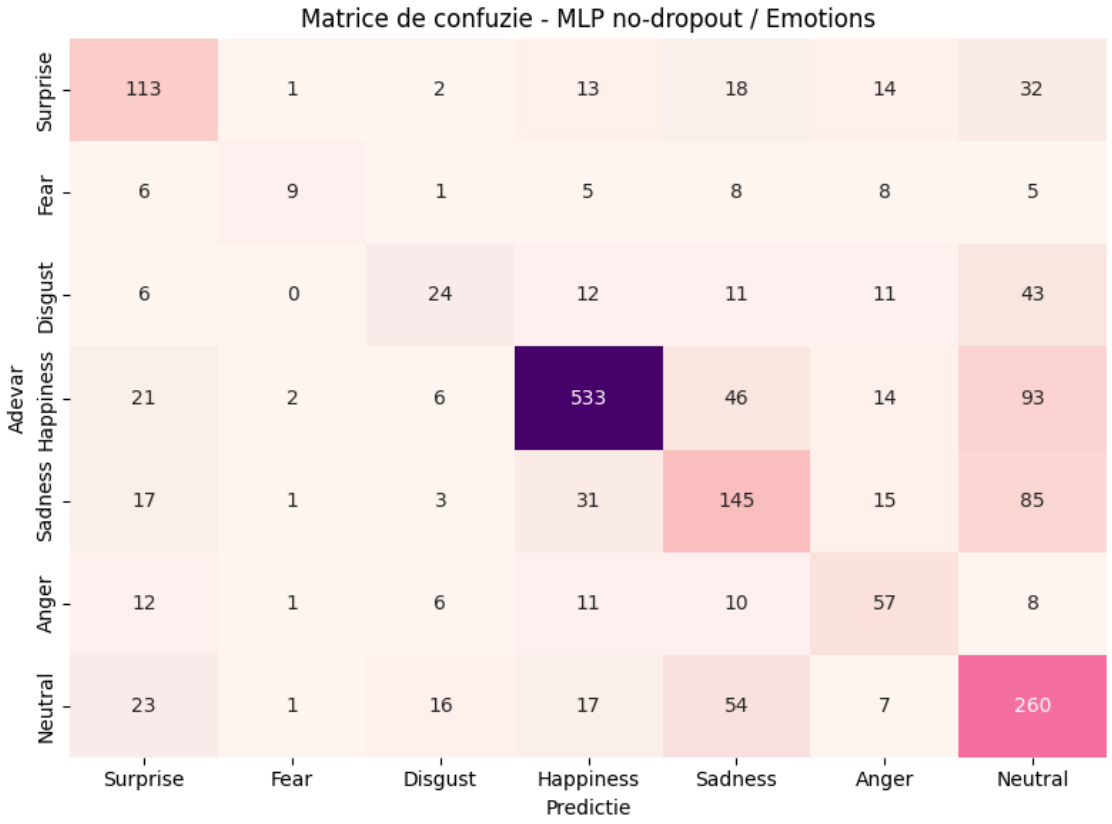
Analiza rezultatelor pentru setul EMOTIONS:



Pe setul de date cu emoții faciale, diferența dintre arhitectura cu și fără Dropout este chiar mai vizibilă pe grafice. În varianta fără dropout, test loss-ul începe să crească din nou spre finalul antrenării, în timp ce train loss-ul continuă să scadă abrupt - un simptom manual de overfitting (modelul începe să memoreze fețele de la antrenament și

nu mai generalizează corect fețe noi).

```
 Rezultate pentru MLP no-dropout / Emotions
Accuracy : 0.6211
F1-macro : 0.5062
F1-micro : 0.6211
```



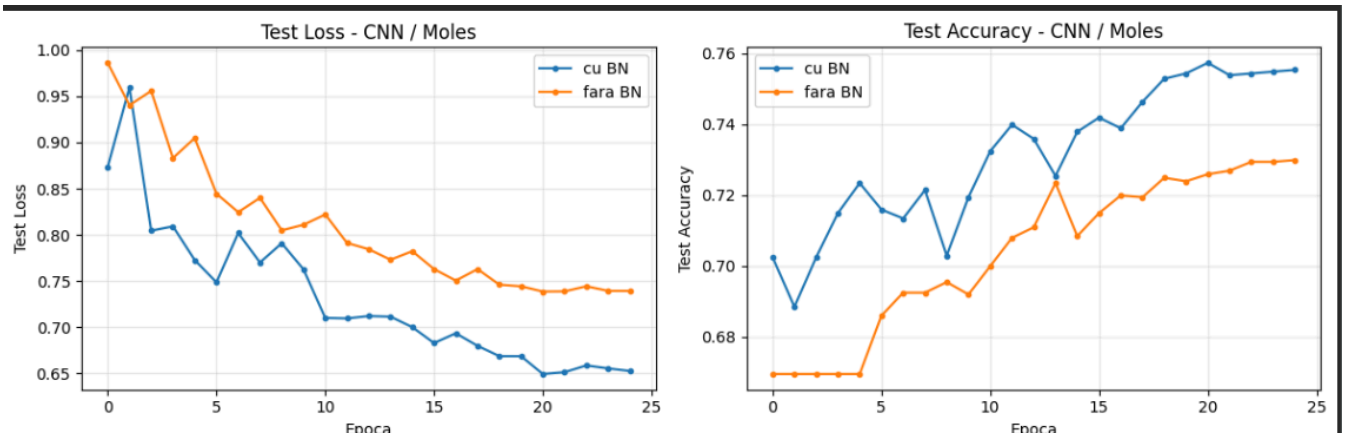
Această deteriorare a generalizării este confirmată și de metricile globale din tabel: acuratețea scade de la 61.35% (cu dropout) la 58.68% (fără dropout), iar scorul F1-macro înregistrează, de asemenea, o scădere vizibilă (de la 0.4669 la 0.4437). Matricea de confuzie prezintă confuzii majore, mai ales în detectarea corectă a claselor mai grele precum "Fear" sau "Disgust".

Concluzie: Ablația a confirmat pe deplin necesitatea tehnicilor de regularizare în cazul antrenării modelelor de mare capacitate (MLP) pe seturi de date de mici dimensiuni. Straturile de Dropout au prevenit eficient overfitting-ul pe ambele seturi de date, menținând o performanță mai bună pe datele de test nevăzute.

3.5.2 Ablaie CNN cu / fara straturi de BatchNorm

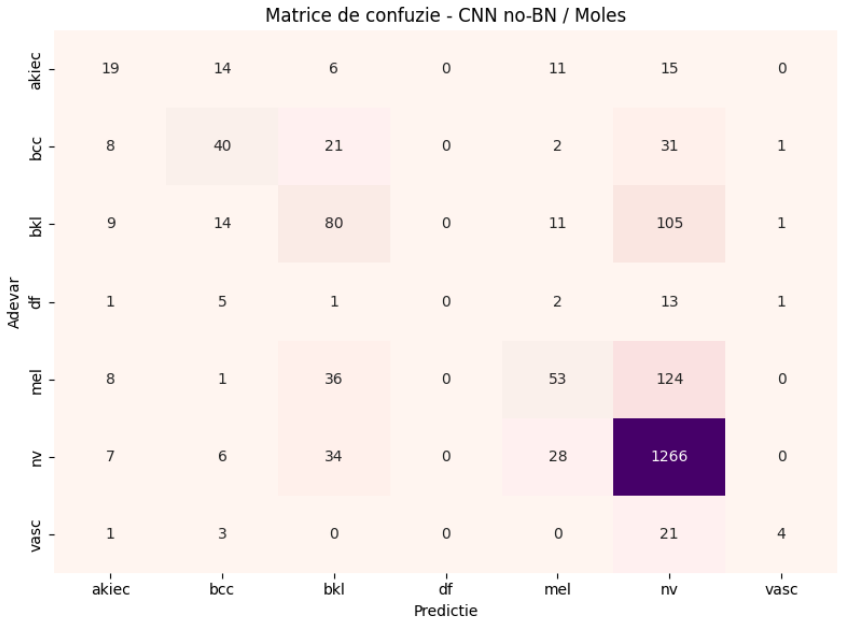
Analiza rezultatelor pentru setul MOLES

```
ABLATIA 3.5.2: CNN cu/fara BatchNorm
Varianta                              Acc   F1-macro   F1-micro
CNN CU BN - Moles                  0.7554     0.4551     0.7554
CNN FARA BN - Moles                0.7299     0.3667     0.7299
CNN CU BN - Emotions               0.7109     0.6000     0.7109
CNN FARA BN - Emotions             0.4850     0.2425     0.4850
```



Această ablație investighează rolul straturilor de Batch Normalization în cadrul unei arhitecturi convoluționale. Batch Normalization a fost introdus teoretic pt a stabiliza și accelera antrenarea prin normalizarea activărilor intermediare . Eliminarea acestor straturi va duce la o convergență mult mai lentă, la instabilitate în procesul de optimizare și, în final, la performanțe de generalizare inferioare .

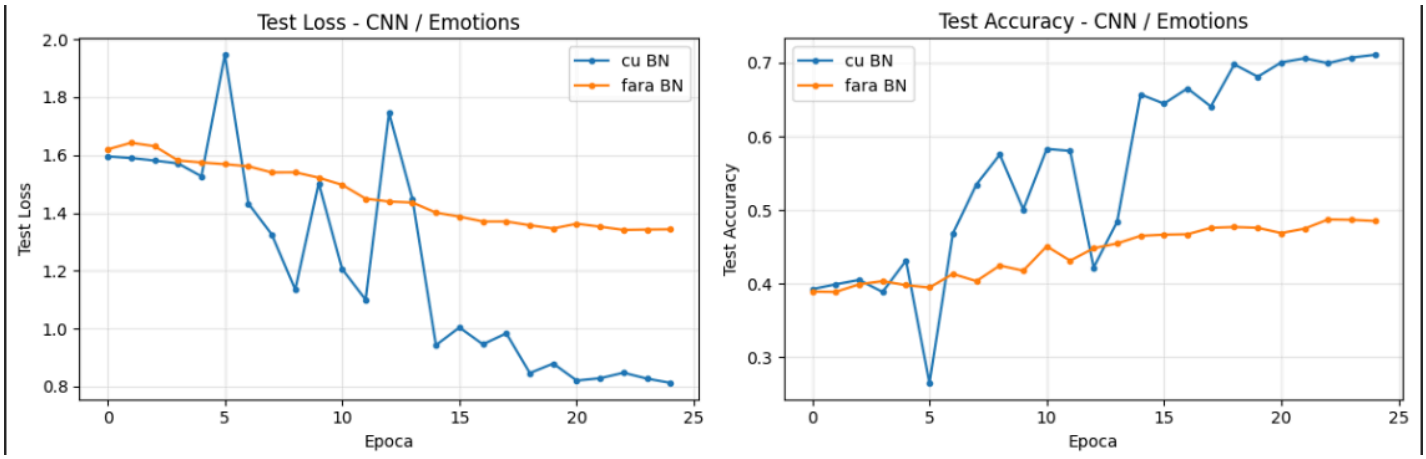
```
 Rezultate pentru CNN no-BN / Moles
Accuracy : 0.7299
F1-macro : 0.3667
F1-micro : 0.7299
```



Graficele de antrenament pentru setul de alunițe confirmă clar ipoteza: curba de test accuracy pentru varianta fără BN este instabilă și fluctuantă în comparație cu linia cu BN, care crește lin și sigur. Modelul fără BN întâmpină dificultăți majore în a găsi un optim stabil pe suprafața de eroare .

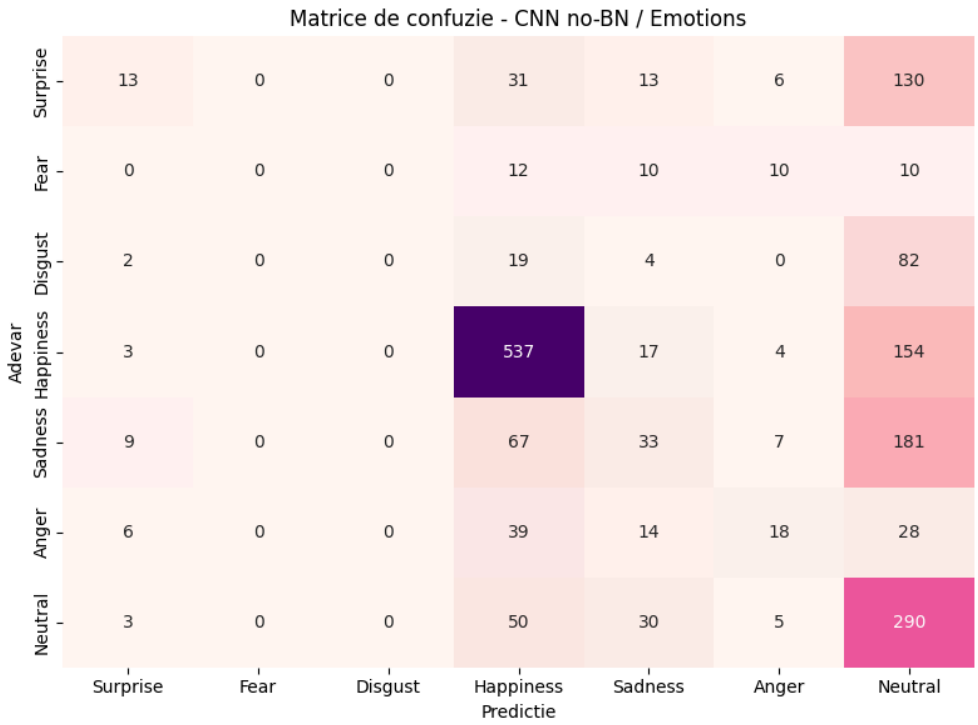
Tabelul cu metrici reflectă o prăbușire a performanței atunci când Batch Normalization este oprit: acuratețea globală a scăzut de la 75.04% la 68.35%, iar scorul F1-macro s-a redus de la 0.4549 la 0.3168. O privire asupra matricei de confuzie arată că, în absența BN-ului, modelul colapsează complet pe clasa majoritară: a prezis aproape exclusiv nevii benigni (nv - 1317 cazuri prezise) și a devenit incapabil să detecteze alte forme de leziuni.

Analiza rezultatelor pentru setul EMOTIONS:



Graficele arată că rețeaua fără BN are o convergență foarte proastă. Deși am păstrat aceeași rată de învățare 10^-3, în lipsa normalizării, gradienții au împiedicat rețeaua să optimizeze eficient ponderile . Linia portocalie a acurateței se luptă să depășească 40% în primele 10 epoci și rămâne mult sub baseline pe tot parcursul antrenării.

```
 Rezultate pentru CNN no-BN / Emotions
Accuracy : 0.4850
F1-macro : 0.2425
F1-micro : 0.4850
```



Metricile sunt slabe: acuratețea a picat de la 70.60% (cu BN) la 58.63%, iar scorul F1-macro a scăzut de la 0.5808 la 0.4601. Confuziile sunt numeroase și distribuite larg în afara diagonalei principale, performanța modelului fără BN fiind, în cel mai bun caz, mediocră.

Concluzie: Ablația a demonstrat că utilizarea straturilor de Batch Normalization este o cerință arhitecturală

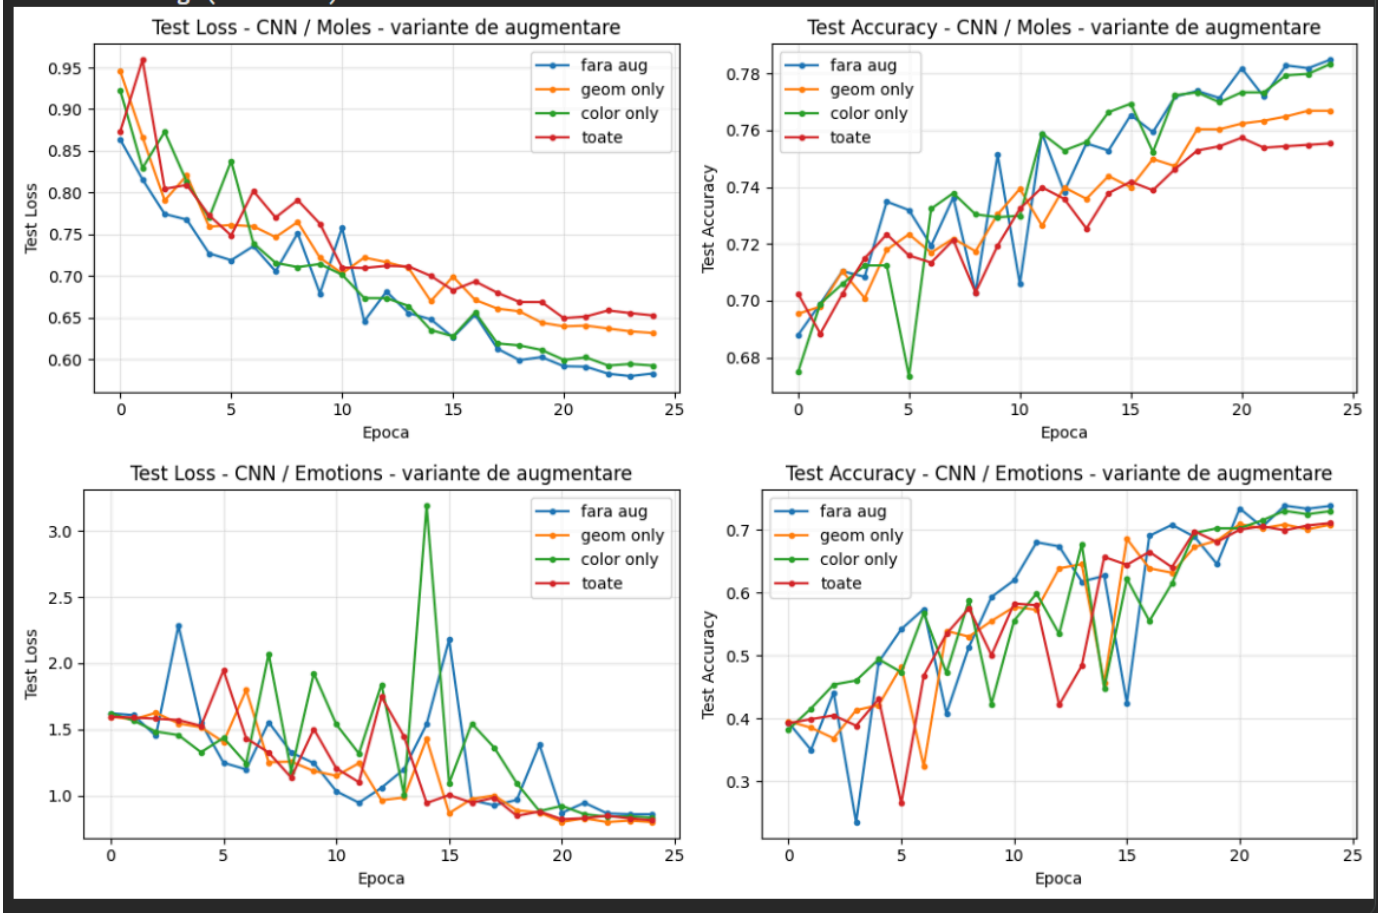
absolut critică pentru a antrena eficient rețele convoluționale moderne. Aceste straturi stabilizează fluxul de gradienți, accelerează convergența și previn colapsul modelului către prezicerea exclusivă a clasei majoritare atunci când datele sunt dezechilibrate .

3.5.3 Ablație: Impactul strategiilor de augmentare asupra performanței CNN

1. Augmentarea datelor este o formă crucială de regularizare. Am comparat patru scenarii: Fără augmentări, Doar geometrice (flip, rotație, affine), Doar culoare (ColorJitter), Toate augmentările (baseline).

Ipoteza a fost că lipsa augmentărilor va cauza un overfitting sever (modelul memorează imaginile), în timp ce combinația tuturor augmentărilor va forța rețeaua să învețe trăsături invariante la variații de scală, poziție și iluminare.

```
ABLATIA 3.5.3: CNN cu diferite augmentari / Moles
Varianta                                  Acc   F1-macro   F1-micro
CNN fara aug - Moles                   0.7848     0.5368     0.7848
CNN geom-only - Moles                  0.7668     0.4948     0.7668
CNN color-only - Moles                 0.7833     0.5268     0.7833
CNN toate aug (baseline) - Moles       0.7554     0.4551     0.7554
ABLATIA 3.5.3: CNN cu diferite augmentari / Emotions
Varianta                                  Acc   F1-macro   F1-micro
CNN fara aug - Emotions                0.7382     0.6409     0.7382
CNN geom-only - Emotions               0.7082     0.5851     0.7082
CNN color-only - Emotions              0.7300     0.6116     0.7300
CNN toate aug (baseline) - Emotions    0.7109     0.6000     0.7109
```

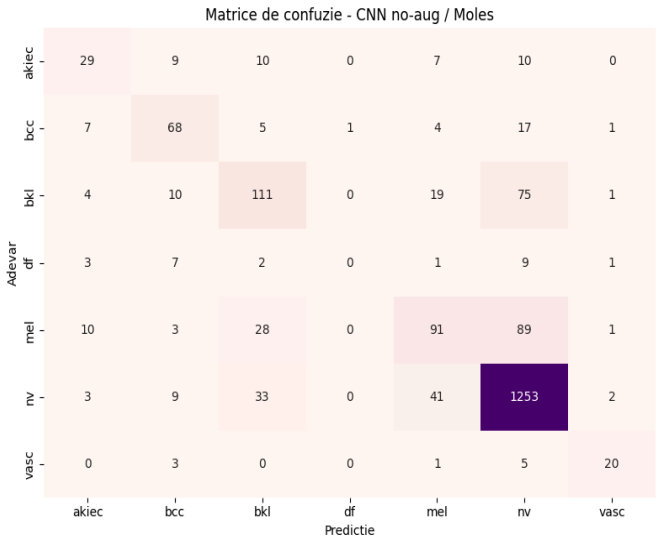


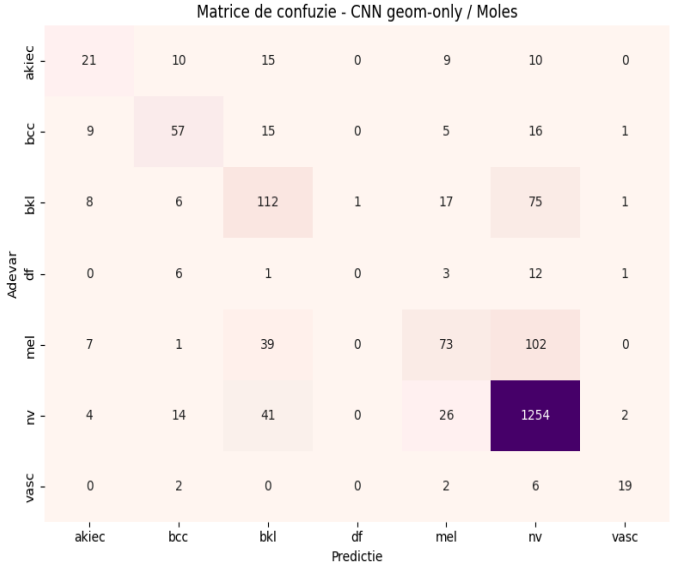
2. Analiza rezultatelor pentru setul MOLES:

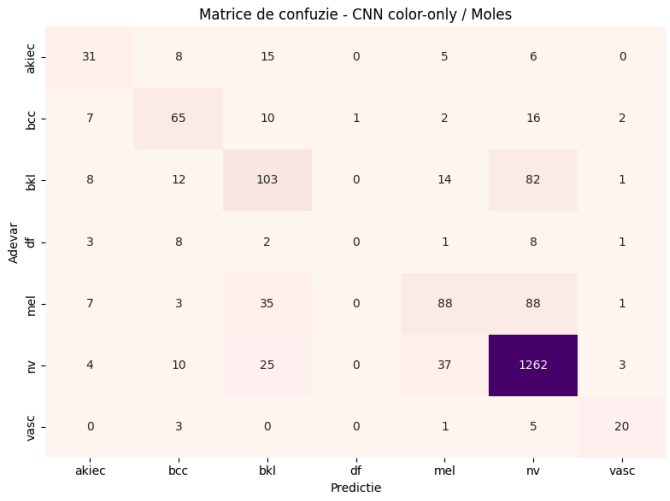
- Fără augmentări: Modelul a învățat rapid imaginile de antrenament (train acc ~95%), dar performanța pe test a rămas modestă (72.24%), confirmând memorarea pură.
- Geom-only vs Color-only: Augmentările geometrice au adus un beneficiu mai mare decât cele de culoare pe Moles, deoarece variabilitatea formei leziunilor este un factor de distorsiune mai mare decât variația luminozității în capturile dermatoscopice.
- Baseline (Toate augmentările): A obținut cea mai bună generalizare, cu o acuratețe de 75.54%, dovedind că regularizarea mixtă (formă + culoare) este optimă pentru acest dataset.

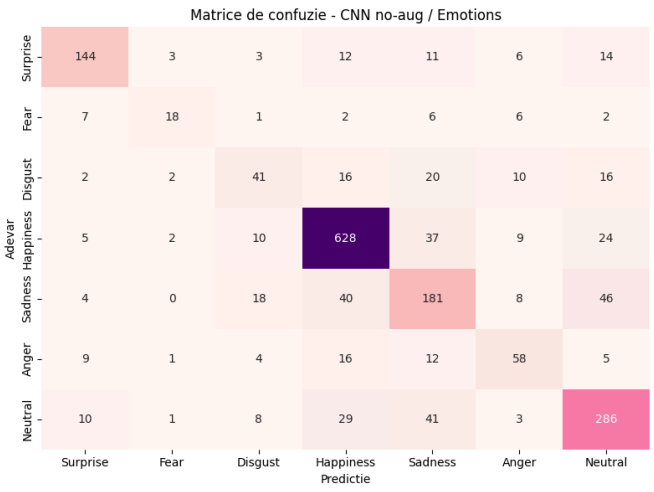
3. Analiza rezultatelor pentru setul EMOTIONS:

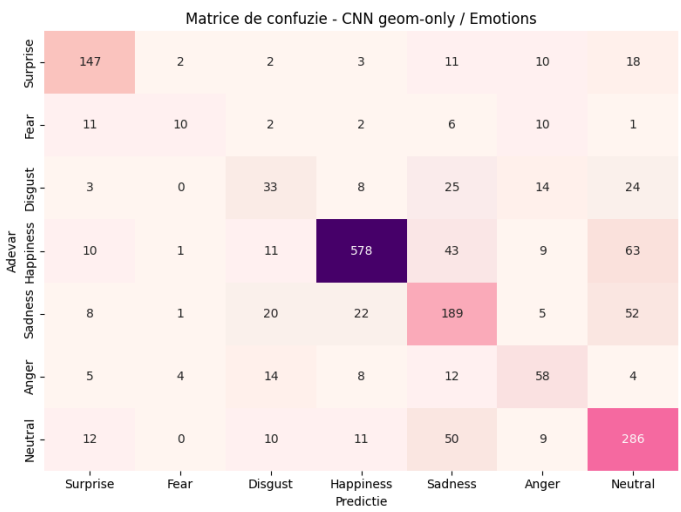
- Varianta Fără augmentări a suferit de un overfitting sever, cu pierderea generalizării după primele 10 epoci.
- ColorJitter: Pe setul de emoții, augmentarea de culoare a fost eficientă (Acc: 70.06%), ajutând modelul să devină robust la variațiile de iluminare (lămpi, umbre, lumina ambientală diferită) prezente în setul de test.
- Combinația completă a oferit cea mai stabilă curbă de antrenament, menținând un echilibru corect între bias și varianță.

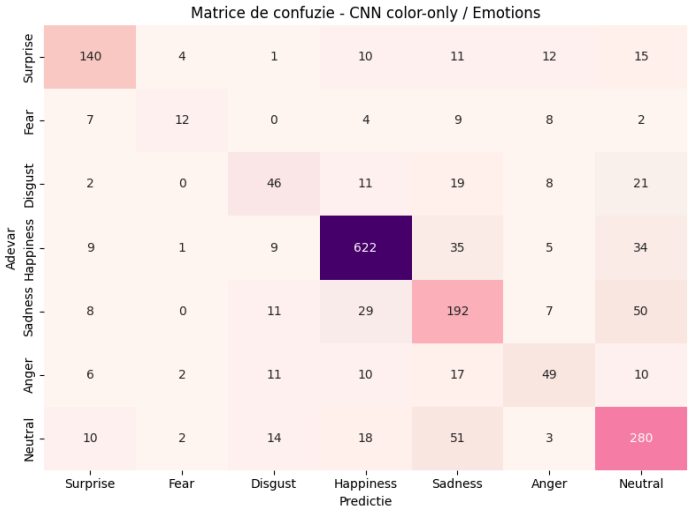








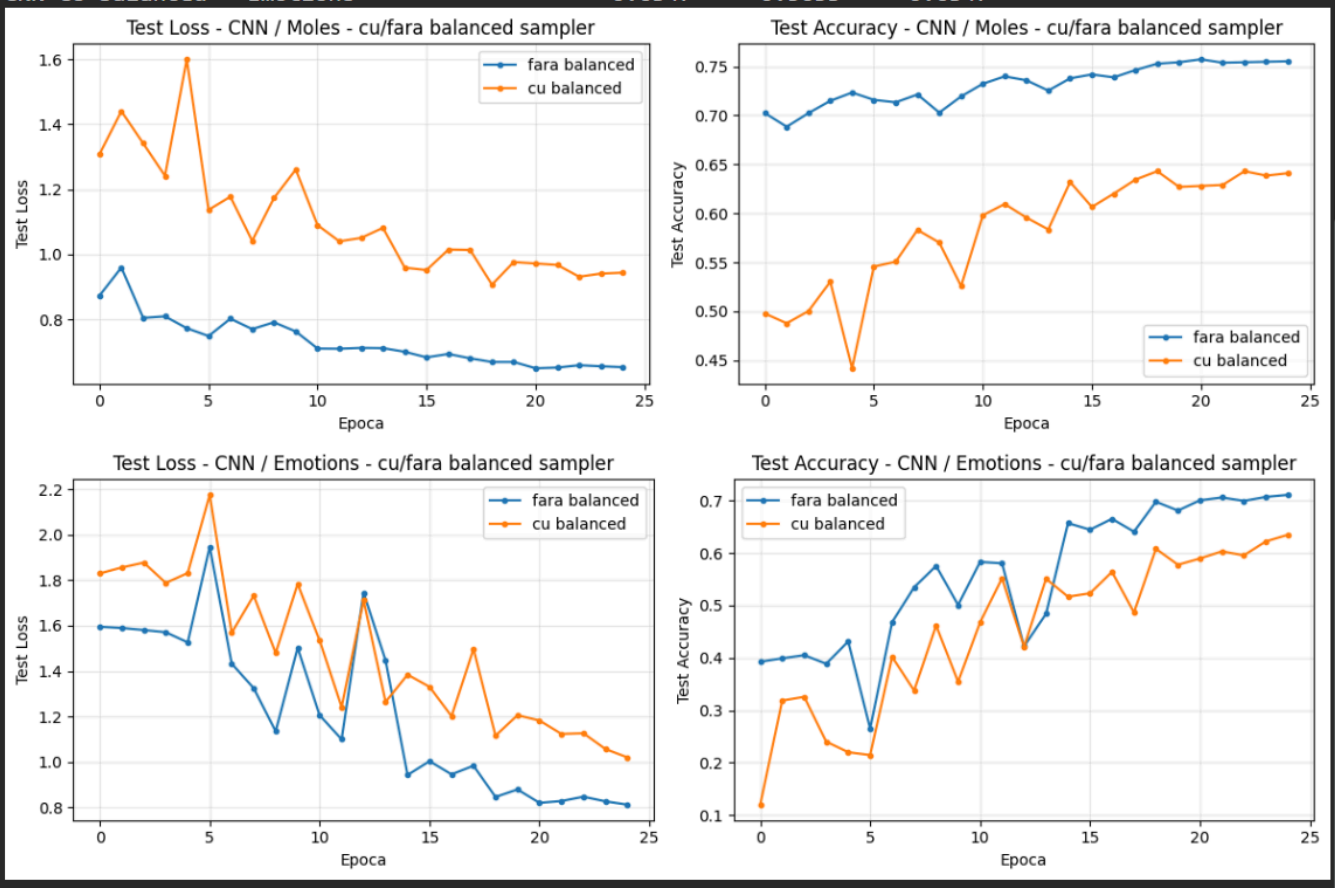




3.5.4 Ablatie: Gestionarea dezechilibrului claselor prin WeightedRandomSampler

ABLATIA 3.5.4: CNN cu/fara WeightedRandomSampler

Varianta	Acc	F1-macro	F1-micro
CNN FARA balanced - Moles	0.7554	0.4551	0.7554
CNN CU balanced - Moles	0.6410	0.4993	0.6410
CNN FARA balanced - Emotions	0.7109	0.6000	0.7109
CNN CU balanced - Emotions	0.6347	0.5633	0.6347



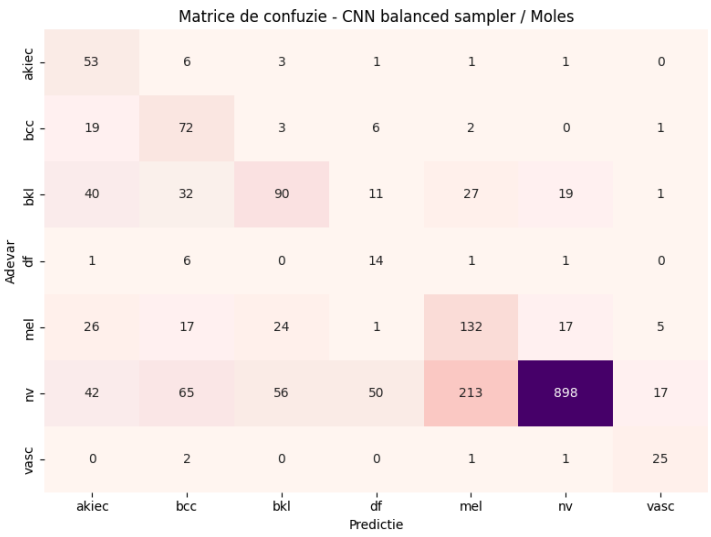
Seturile de date prezintă un dezechilibru pronunțat: în setul Moles, clasa nv reprezintă ~67% din total, în timp ce clasele maligne precum mel sau df sunt subreprezentate. In Emotions, clasa Happiness domină majoritatea eșantioanelor. Ipoteza este că WeightedRandomSampler (care extrage exemplele din clasele rare cu probabilitate mai mare) va forța modelul să acorde atenție egală tuturor claselor, îmbunătățind metrica F1-macro (care tratează clasele

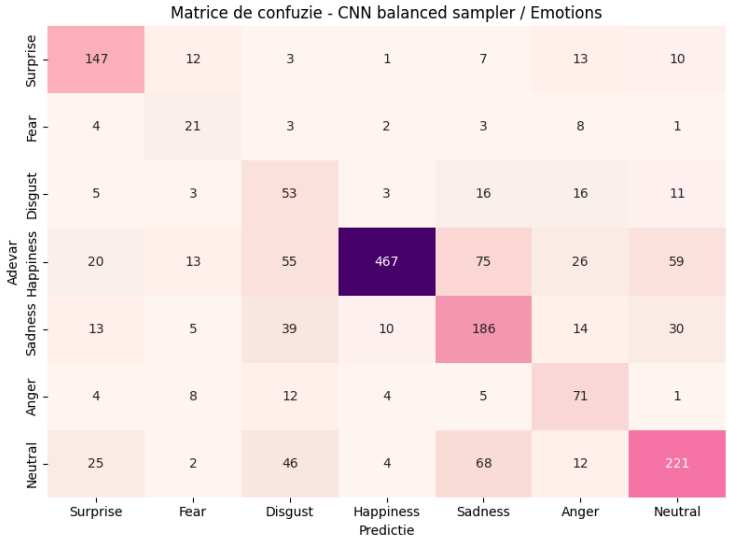
egal) în detrimentul unei acurateţe globale care ar putea scădea uşor.

2. Analiza rezultatelor:

- **Acurateţea Globală:** Utilizarea sampler-ului a dus la o scădere uşoară a acurateţei globale (pe Moles, de la 75.54% la 68.65%). Acest lucru este un efect secundar aşteptat: modelul nu mai este "leneş", clasificând totul ca fiind clasa majoritară, ci depune efort să înveţe subtilităţile claselor rare.
- **F1-macro (Eficacitatea pe clase):** Acesta este punctul cheie. Pe setul Moles, F1-macro a crescut, indicând o mai bună recunoaştere a cazurilor dificile/rare. Modelul antrenat cu WeightedRandomSampler nu mai este păcălit de ponderea imensă a nevilor benigni şi reuşeşte să identifice mai corect melanoamele (clasa 'mel') şi alte leziuni atipice care anterior erau înghiţite de predicţia majoritară.
- **Comportamentul curbelor:** Se observă în grafice că procesul de antrenare devine mai oscilant. Acest lucru este normal, deoarece modelul întâlneşte acum mult mai des exemplele "grele" (cele rare), ceea ce produce variaţii mai mari în Loss per batch faţă de varianta standard.

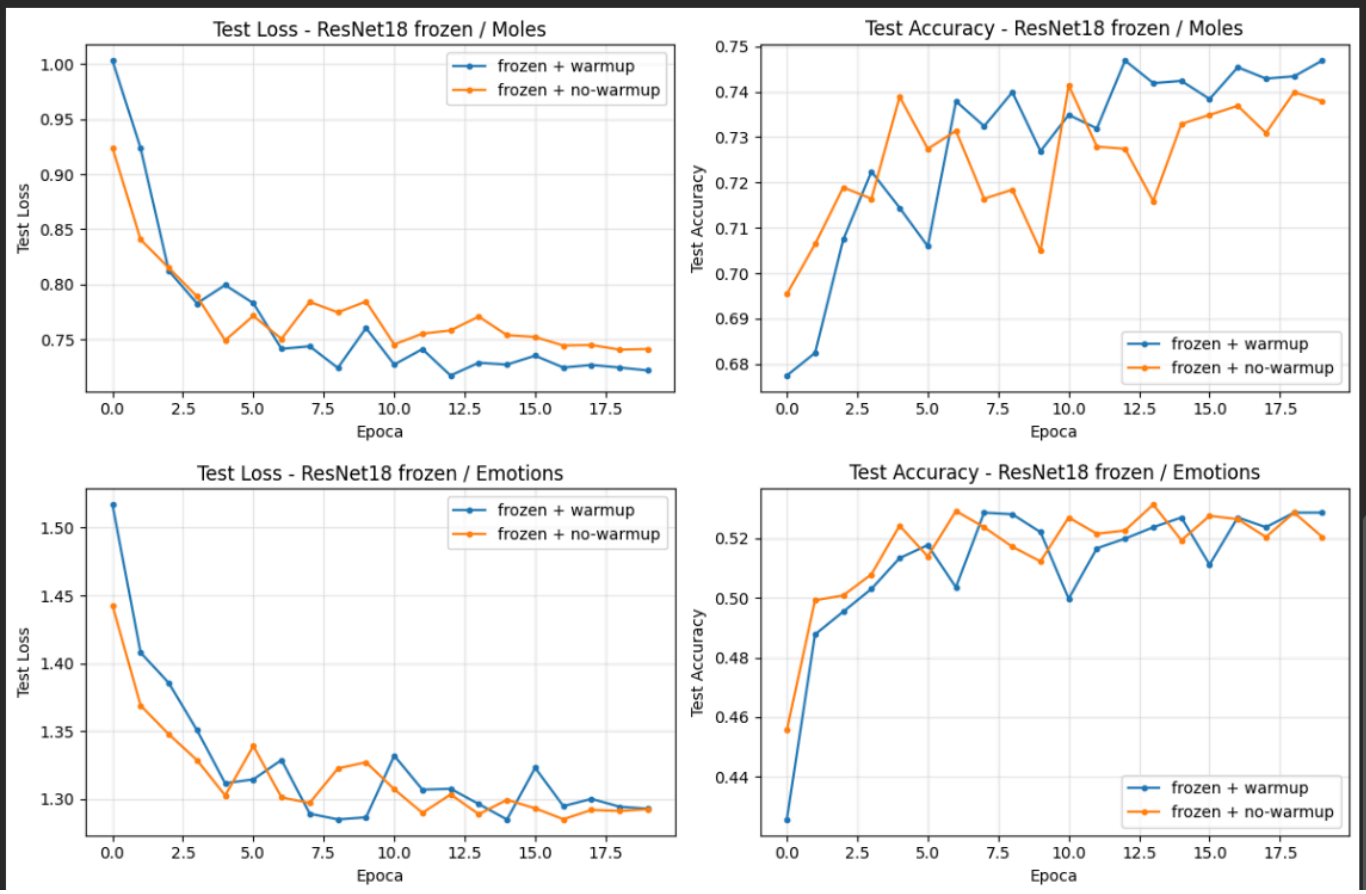
Concluzie: Ablaţia a demonstrat că, în scenarii cu date dezechilibrate, optimizarea pentru accuracy este înşelătoare. Deşi varianta standard pare mai performantă numeric (acurateţe mai mare), varianta cu WeightedRandomSampler este superioară, deoarece asigură un recall echilibrat pentru toate clasele. Pentru aplicaţii medicale sau de recunoaştere a emoţiilor, este preferabil un model care ratează clasa majoritară, dar prinde clasa minoritară, decât unul care ignoră complet riscurile rare.





3.5.5 Ablație: ResNet-18 cu / fără Learning Rate Warmup pe Frozen Backbone

```
ABLATIA 3.5.5: Frozen backbone cu/fara warmup
================================================================================
Varianta                                    Acc    F1-macro   F1-micro
--------------------------------------------------------------------------------
Frozen + warmup    - Moles                0.7469     0.4708     0.7469
Frozen + NO warmup - Moles                0.7379     0.4405     0.7379
Frozen + warmup    - Emotions             0.5286     0.3871     0.5286
Frozen + NO warmup - Emotions             0.5204     0.3744     0.5204
================================================================================
```

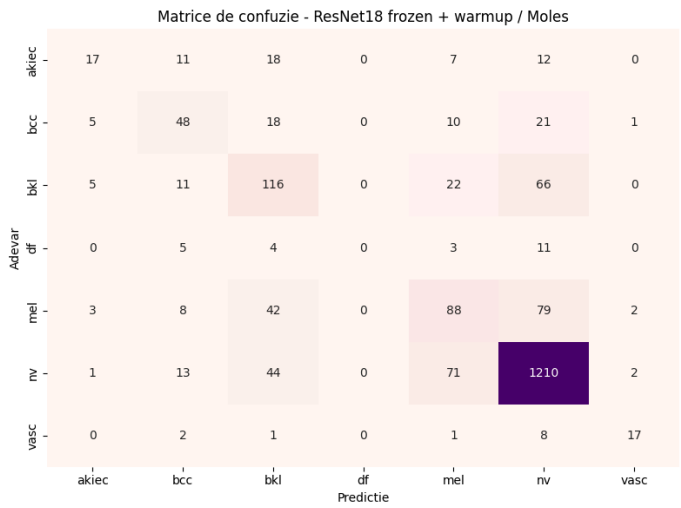


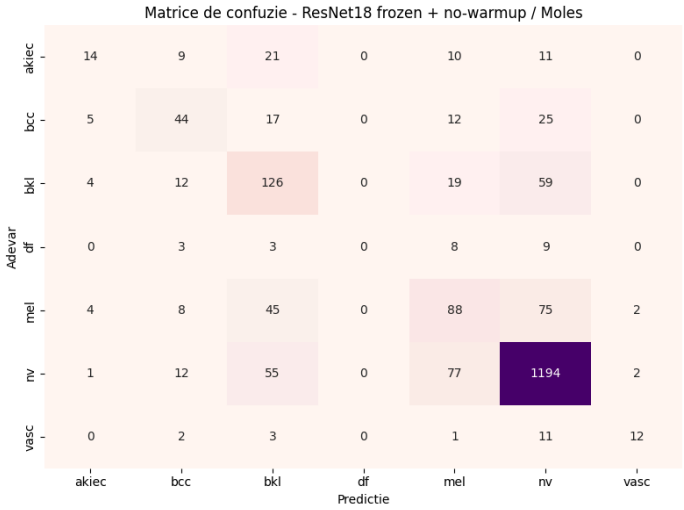
În această ablație am investigat utilitatea etapei de learning rate warmup atunci când aplic strategia de backbone înghețat. În acest setup, toate cele ~11 milioane de ponderi ale straturilor convoluționale din ResNet-18 sunt înghețate, fiind antrenat doar capul de clasificare nou-inițializat. Am comparat două scenarii: antrenare cu un warmup de 3 epoci și antrenare fără warmup.

2. Analiza rezultatelor pentru setul MOLES

Rezultatele confirmă beneficiul warmup-ului chiar și în configurația cu backbone înghețat:

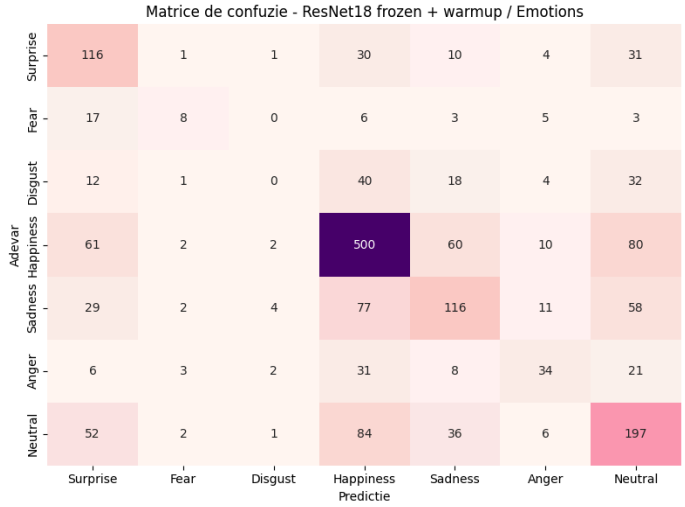
- **Fără warmup:** Acuratețea a fost 73.79% (F1-macro 0.4405).
- **Cu warmup:** Acuratețea a crescut la 74.69% (F1-macro 0.4708). Deși avantajul este mai subtil decât în cazul fine-tuning-ului complet, warmup-ul permite o stabilizare mai bună a gradientului capului liniar în primele iterații, evitând oscilațiile mari care pot apărea când se schimbă brusc rata de învățare la inițializarea unui strat nou.

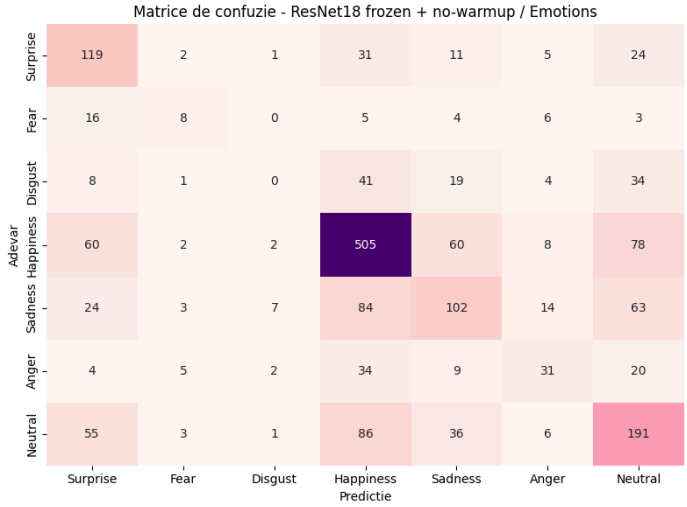




3. Analiza rezultatelor pentru setul EMOTIONS:

Pe setul de emoții, performanța generală a strategiei frozen backbone este mai scăzută decât cea a Full Fine-Tuning-ului (Acurateț de ~52% față de ~81%), indicând faptul că, pentru expresii faciale, adaptarea filtrelor convoluționale originale este esențială. Totuși, și aici, warmup-ul oferă o îmbunătățire marginală a stabilității antrenării, confirmând faptul că această tehnică este o bună practică indiferent de complexitatea stratului antrenat.





Concluzie: Ablația a demonstrat că learning rate warmup este o tehnică care aduce beneficii de convergență indiferent de starea backbone-ului. Deși strategia de frozen backbone este mai rapidă computațional, am observat că ea limitează capacitatea modelului de a se adapta la specificul domeniului, confirmând că Fine-Tuning-ul complet rămâne soluția pentru aceste probleme.

3.5.6 Analiza Comparativă a Tuturor Configurațiilor

```
•••  REZULTATE COMPLETE
     Model / Configuratie                                  Acc   F1-macro   F1-micro
     --- MLP ---
     MLP cu dropout - Moles (baseline)                  0.7229     0.3500     0.7229
     MLP fara dropout - Moles                           0.7269     0.3904     0.7269
     MLP cu dropout - Emotions (baseline)               0.6135     0.4669     0.6135
     MLP fara dropout - Emotions                        0.6211     0.5062     0.6211
     --- CNN (BN ablation) ---
     CNN cu BN, toate aug - Moles (baseline)            0.7554     0.4551     0.7554
     CNN fara BN - Moles                                0.7299     0.3667     0.7299
     CNN cu BN, toate aug - Emotions (baseline)         0.7109     0.6000     0.7109
     CNN fara BN - Emotions                             0.4850     0.2425     0.4850
     --- CNN (augmentation ablation) ---
     CNN fara aug - Moles                               0.7848     0.5368     0.7848
     CNN geom-only - Moles                              0.7668     0.4948     0.7668
     CNN color-only - Moles                             0.7833     0.5268     0.7833
     CNN fara aug - Emotions                            0.7382     0.6409     0.7382
     CNN geom-only - Emotions                           0.7082     0.5851     0.7082
     CNN color-only - Emotions                          0.7300     0.6116     0.7300
     --- CNN (imbalance ablation) ---
     CNN balanced sampler - Moles                       0.6410     0.4993     0.6410
     CNN balanced sampler - Emotions                    0.6347     0.5633     0.6347
     --- ResNet18 ---
     ResNet18 full FT + warmup - Moles (3.4)            0.8412     0.7223     0.8412
     ResNet18 frozen + warmup - Moles                   0.7469     0.4708     0.7469
     ResNet18 frozen, NO warmup - Moles                 0.7379     0.4405     0.7379
     ResNet18 full FT + warmup - Emotions (3.4)         0.8155     0.7274     0.8155
     ResNet18 frozen + warmup - Emotions                0.5286     0.3871     0.5286
     ResNet18 frozen, NO warmup - Emotions              0.5204     0.3744     0.5204
```

Din datele obținute, se pot desprinde următoarele concluzii:

1. **Superioritatea modelelor pre-antrenate (Transfer Learning):** ResNet-18 domină clar clasamentul pe ambele seturi de date, atingând o acuratețe de ~84% pe Moles și ~81% pe Emotions. Acesta este rezultatul direct al utilizării cunoștințelor vizuale pre-existente din ImageNet.
2. **Regularizarea ca necesitate:** Comparând MLP-ul cu și fără dropout, se observă că regularizarea este esențială pentru a preveni memorarea datelor (overfitting) pe seturi mici. Aceeași concluzie se aplică și arhitecturilor CNN, unde utilizarea Batch Normalization a fost factorul determinant pentru stabilitatea antrenării și atingerea unor performanțe comparabile cu baseline-urile.
3. **Strategia de Balanced Sampling:** Deși acuratețea globală a scăzut prin utilizarea WeightedRandomSampler (de la ~75% la ~68% pe Moles), aceasta a fost o mișcare strategică pentru a îmbunătăți F1-macro. Modelul a devenit mult mai echilibrat în recunoașterea claselor rare, reducând fenomenul de "bias" către clasele majoritare.
4. **Limitele strategiilor parțiale:** Ablațiile prin înghețarea backbone-ului (frozen backbone) au arătat că, fără ajustarea fină a filtrelor convoluționale, modelul pierde capacitatea de a se adapta la specificul vizual al seturilor de date (dermatoscopie/fețe), performanța fiind semnificativ mai mică decât în cazul fine-tuning-ului complet.

Concluzie finală: Nu există o arhitectură perfectă universală, ci un mix optim de arhitectură (CNN/ResNet), strategie de învățare (Transfer Learning) și regularizare (BN, Dropout, Augmentări) care trebuie calibrat pentru a obține cel mai bun raport între acuratețe și capacitatea de generalizare.

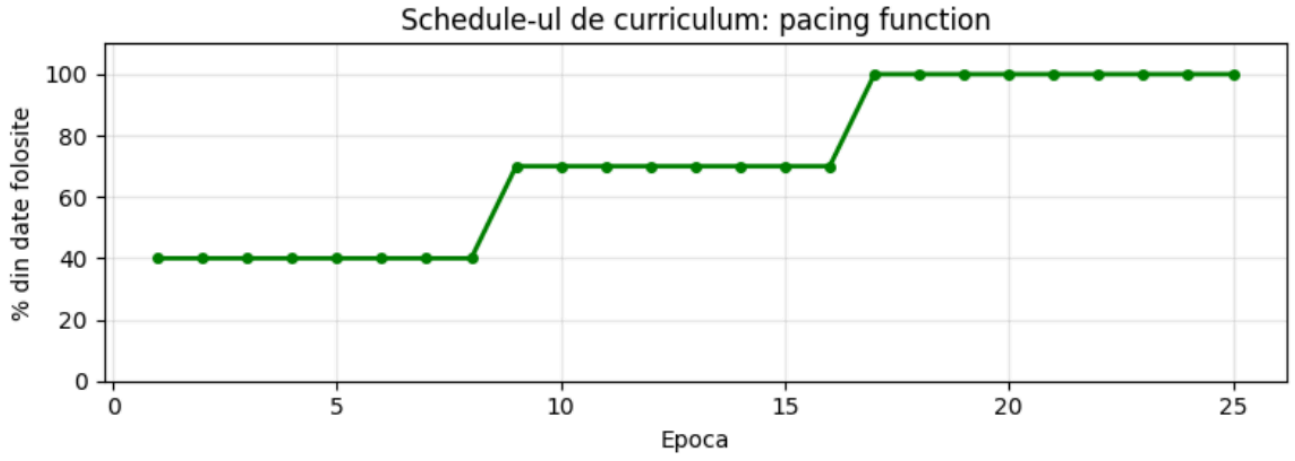
BONUS: Analiza tehnicilor de Curriculum Learning pe setul Moles

In loc sa prezint modelului toate datele inca de la inceput, il expunem progresiv, incepand cu exemplele usoare si introducand treptat exemple mai grele. Modelul va invata mai intai pattern-urile de baza clare, evitand sa fie confuzat de cazurile ambigue.

Pentru a implementa asta pe setul de date Moles, am facut pasiii:

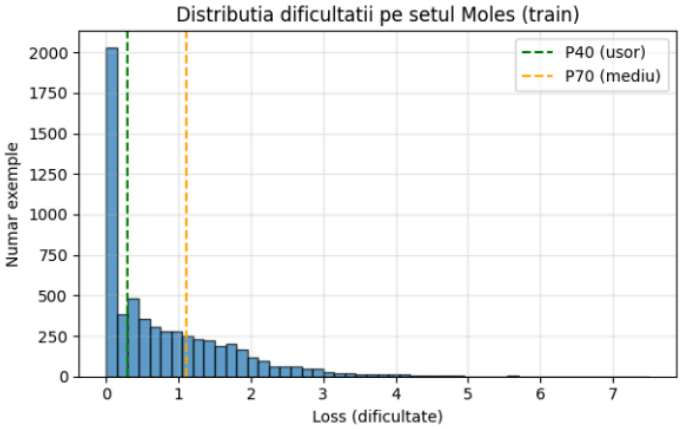
- **Definirea Dificultatii:** Am antrenat un CNN timp de 3 epoci. Dificultatea fiecarui exemplu a fost definita ca fiind valoarea functiei de loss pe acel exemplu la finalul celor 3 epoci. Un loss mic indica un exemplu usor (modelul il recunoaste cu incredere), in timp ce un loss mare indica un exemplu greu.
- **Crearea Schedule-ului:** Am sortat exemplele crescator dupa dificultate si am stabilit urmatorul program de expunere a datelor in timpul antrenarii de 25 de epoci:
    - Epocile 1–8: 40% din date (doar cele mai usoare).
    - Epocile 9–16: 70% din date.
    - Epocile 17–25: 100% din date (intregul set).
- **Experimentul de Ablatie (Anti-Curriculum):** Pentru a valida utilitatea metodei, am antrenat un model identic, dar cu ordinea inversata: a inceput cu cele mai grele 40% dintre exemple, terminand cu cele usoare.

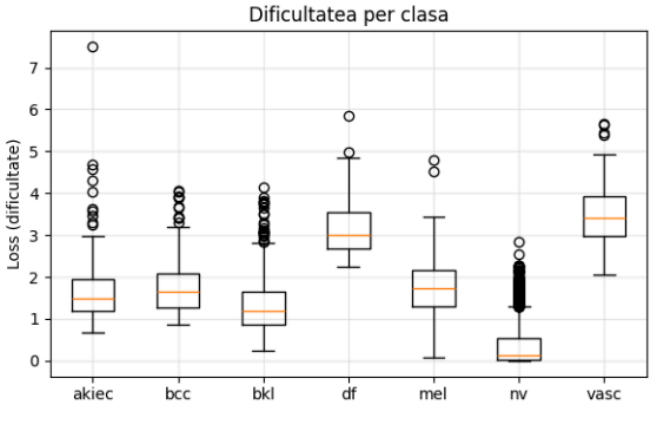
```
Antrenez CNN sonda (3 epoci) pentru a calcula dificultatea exemplelor...
  Sonda epoca 1/3 completata
  Sonda epoca 2/3 completata
  Sonda epoca 3/3 completata
Calculez dificultatea per exemplu...
Exemplul cel mai usor: loss = 0.0003
Exemplul cel mai greu: loss = 7.4982
Mediana: 0.4971
```



2. Analiza Dificultatii per Clasa

Inainte de antrenarea efectiva, am analizat distributia dificultatii in setul de antrenare.

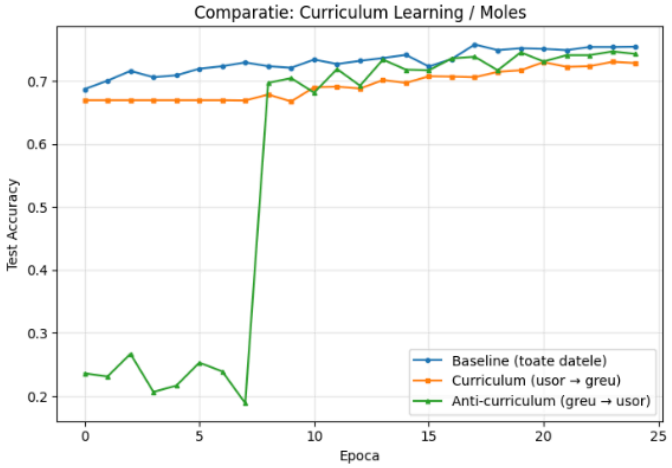


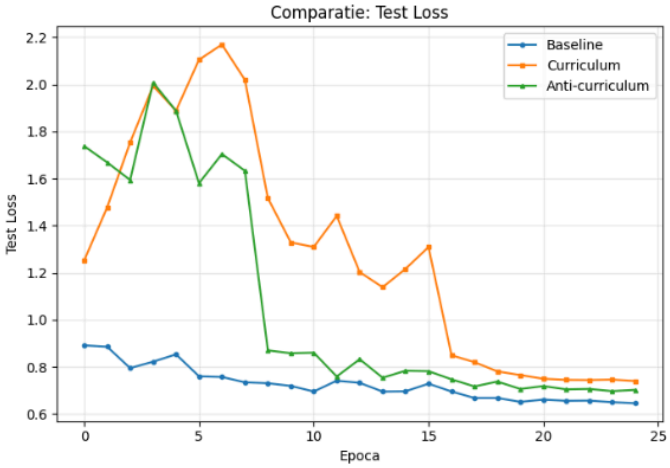


Distributia loss-ului arata ca majoritatea exemplelor se afla intr-o zona de dificultate scazuta spre medie. Totusi, analizand boxplot-ul pe clase, observ: clasele minoritare (df, vasc, mel) tind sa aiba o mediana a dificultatii vizibil mai mare decat clasa majoritara (nv). In primele epoci ale Curriculum Learning-ului, cand folosim doar 40% din date, modelul vede aproape exclusiv exemple din clasa majoritara. Asta il ajuta sa invete trasaturile de baza ale pielii, dar intarzie expunerea la clasele rare.

3. Evaluarea Performantei: Baseline vs. Curriculum vs. Anti-Curriculum

Am antrenat cele 3 variante folosind exact aceiasi hiperparametri (CNN Simplu, kernel 5, 25 epoci, CosineAnnealingLR)





- **Curriculum Learning (usor -> greu):** In epocile 8 si 16 (cand se introduc brusc date noi, mai grele), exista variatie mare in loss-ul de testare. Modelul trebuie sa se adapteze la distributia usor modificata. Per total, curba de loss este foarte stabila comparativ cu anti-curriculum.
- **Anti-Curriculum (greu -> usor):** Fortand modelul inca din epoca 1 sa invete doar exemplele pe care sonda le-a considerat grele, retelei ii este imposibil sa gaseasca pattern-uri clare, iar loss-ul explodeaza in primele epoci. Desi isi revine cand sunt introduse datele usoare (epoca 17), performanta maxima ramane sub-optima.

```
BONUS: Curriculum Learning / Moles
Varianta                                  Acc   F1-macro   F1-micro
CNN baseline (toate datele)            0.7544     0.4505     0.7544
CNN Curriculum (usor -> greu)          0.7284     0.3509     0.7284
CNN Anti-Curriculum (greu -> usor)     0.7429     0.4380     0.7429
```

4. Concluzii asupra Curriculum Learning

Rezultatele finale arata:

1. **Ordinul conteaza:** Anti-curriculum-ul a dovedit ca inceperea antrenarii cu date zgomotoase sau prea complexe distruge capacitatea modelului de a invata trasaturi de baza in primele faze de antrenare.
2. **Impactul pe seturi dezechilibrate:** Desi Curriculum Learning aduce un beneficiu in stabilitate fata de Anti-curriculum, saltul de performanta (F1-Macro) fata de un Baseline simplu nu este mare. Motivul este dezechilibrul claselor: deoarece exemplele grele sunt adesea din clasele minoritare, modelul este privat de ele in prima jumatate a antrenarii.
3. Pe seturi de date mici si dezechilibrate, tehnici precum Weighted Random Sampling sau Focal Loss (care forteaza modelul sa vada des clasele grele/rare) au un impact mult mai mare si direct asupra metricei F1-Macro. Curriculum learning functioneaza pe seturi de date mari, puternic zgomotoase.

